



Pontificia Universidad
JAVERIANA
Cali

**Modelo predictivo del abandono estudiantil en entornos LMS
mediante aprendizaje automático: análisis de factores académicos,
conductuales y temporales**

**Oriana Giraldo Arcia
Luis Javier Rubio Hernández**

Anteproyecto del Proyecto Aplicado para optar al título de Magíster en Ciencia de Datos

Director: Gerardo Mauricio Sarria Montemiranda

**Facultad de Ingeniería y Ciencias
Maestría en Ciencia de Datos
Santiago de Cali,
Junio, 16 de 2026**

Ficha Resumen Anteproyecto de Trabajo de Grado

POSIBLE TÍTULO: Modelo predictivo del abandono estudiantil en entornos LMS mediante aprendizaje automático: análisis de factores académicos, conductuales y temporales

ÁREA DE TRABAJO: Ciencia de Datos

TIPO DE PROYECTO: Aplicado

ESTUDIANTES: Oriana Giraldo Arcia, Luis Javier Rubio Hernández

CORREO ELECTRÓNICO: ogiraldoarcia35@javerianacali.edu.co, luisjrubioh@javerianacali.edu.co

DIRECCIÓN Y TELÉFONO: Cra 103, 95-23 Chigorodó, Antioquia. 3006230530, 3207406855

DIRECTOR: Gerardo Mauricio Sarria Montemiranda

VINCULACIÓN DEL DIRECTOR: Docente de planta

CORREO ELECTRÓNICO DEL DIRECTOR: gsarria@javerianacali.edu.co

PALABRAS CLAVE: Deserción estudiantil, predicción temprana, aprendizaje automático, analítica de aprendizaje, LMS, interpretabilidad, SHAP, OULAD, variables temporales.

ODS QUE APLICA EL PROYECTO (Agenda 2030): Educación de calidad, Reducción de las desigualdades.

FECHA DE INICIO: Julio de 2026

DURACIÓN ESTIMADA: 9 meses

RESUMEN:

El presente proyecto aplicado aborda la predicción temprana del abandono estudiantil en entornos mediados por Sistemas de Gestión de Aprendizaje (LMS), mediante técnicas de aprendizaje automático aplicadas al *Open University Learning Analytics Dataset* (OULAD). La deserción en modalidades virtuales constituye una problemática persistente que afecta indicadores institucionales, reduce oportunidades de movilidad social y representa una pérdida significativa de inversión académica; de hecho, en contextos en línea las tasas de abandono superan considerablemente las de la educación presencial, lo que subraya la necesidad de contar con estrategias proactivas de detección. El problema central radica en que muchas instituciones actúan de forma reactiva frente al abandono, sin aprovechar los registros de interacción que las plataformas educativas generan de manera continua. Ante esta situación, el proyecto propone transformar dichos registros en señales tempranas de riesgo, operacionalizando el abandono a

partir del retiro voluntario registrado en la plataforma y explorando, además, la identificación de inactividad prolongada como indicador complementario. Para ello se plantean cinco objetivos específicos: identificar y caracterizar las variables académicas, conductuales y temporales disponibles en el dataset; derivar indicadores de interacción estudiantil como frecuencia de acceso, regularidad de participación y variación temporal de la actividad; desarrollar y comparar modelos supervisados de clasificación; analizar la interpretabilidad del modelo seleccionado para identificar las variables con mayor incidencia en la clasificación de riesgo; y diseñar un prototipo de visualización exploratoria que comunique los resultados de forma comprensible. Como productos del proyecto se esperan un dataset analítico documentado con variables derivadas, una comparación sistemática de modelos, un modelo predictivo acompañado de análisis de interpretabilidad y un prototipo visual orientado a actores educativos. En cuanto a sus posibles aplicaciones, los resultados podrán servir como insumo metodológico para el diseño de sistemas de alerta temprana en instituciones de educación superior que operen con plataformas LMS, facilitando así el seguimiento académico y el acompañamiento oportuno de estudiantes en riesgo de abandono.

Índice general

Ficha Resumen Anteproyecto de Trabajo de Grado	1
Lista de Figuras	4
Lista de Tablas	5
1. Introducción	6
2. Definición del Problema	7
2.1. Planteamiento del Problema	7
2.2. Formulación del Problema	8
2.2.1. Preguntas de sistematización	8
3. Objetivos del Proyecto	9
3.1. Objetivo General	9
3.2. Objetivos Específicos	9
3.3. Resultados Esperados	9
4. Alcance	11
5. Justificación	13
6. Marco de Referencia	14
6.1. Marco Teórico	14
6.2. Antecedentes	16
7. Recursos a Emplear	18
7.1. Recursos Humanos	18
7.2. Ética y Datos	18
7.3. Recursos Bibliográficos y de Información	20
7.4. Otros Recursos	20
8. Metodología	21
8.1. Actividades por Objetivo Específico	21
8.1.1. Objetivo específico 1	21
8.1.2. Objetivo específico 2	21
8.1.3. Objetivo específico 3	22
8.1.4. Objetivo específico 4	23
8.1.5. Objetivo específico 5	23
9. Cronograma de Actividades	24
Bibliografía	25

LISTA DE FIGURAS

Figura 1: Esquema relacional del dataset OULAD 19

LISTA DE TABLAS

Tabla 1: Cronograma de actividades del proyecto 24

1. Introducción

En América Latina, aproximadamente la mitad de los jóvenes que inician una carrera universitaria la abandona antes de obtener el título [2]. En Colombia, esa proporción ha alcanzado históricamente cifras cercanas al 44,9 %, con áreas como ingeniería y tecnología donde las tasas superan el 60 % [4]. Cuando el aprendizaje ocurre en entornos virtuales o mediados por plataformas digitales, el panorama se agudiza: la separación física entre docente y estudiante dificulta la detección oportuna de señales de desconexión, y las tasas de abandono reportadas en cursos en línea alcanzan niveles considerablemente superiores a los de la educación presencial [5], [6].

Las plataformas donde se desarrolla este fenómeno registran, paradójicamente, un volumen continuo de datos sobre la actividad de cada estudiante: frecuencia de acceso, interacción con recursos, entrega de evaluaciones, regularidad de participación y patrones temporales de uso. Pese a ello, en muchas instituciones estos registros permanecen infrautilizados y el acompañamiento académico continúa operando desde enfoques reactivos que intervienen cuando la pérdida del estudiante ya se ha consumado [8]. La analítica de aprendizaje y la minería de datos educativa han demostrado que es posible transformar esas trazas de interacción en señales tempranas de riesgo mediante modelos supervisados de aprendizaje automático [16], [17]. Con todo, la literatura reciente advierte que la capacidad predictiva del modelo resulta insuficiente si los resultados carecen de explicaciones comprensibles para los actores educativos y si las predicciones llegan demasiado tarde para orientar acciones de apoyo [10], [11].

Ante este panorama, el presente proyecto propone el desarrollo de un modelo predictivo temprano e interpretable de aprendizaje automático, orientado a identificar estudiantes en riesgo de abandono en entornos mediados por Sistemas de Gestión de Aprendizaje (LMS). Para ello se utilizará el *Open University Learning Analytics Dataset* (OULAD), un conjunto de datos público y anonimizado que integra información sociodemográfica, registros de matrícula, resultados de evaluación e interacciones diarias con el entorno virtual. A partir de estas fuentes se construirán variables académicas, conductuales y temporales que permitan representar la trayectoria del estudiante como un proceso dinámico, y se entrenarán y compararán modelos supervisados de clasificación con énfasis en su capacidad predictiva temprana y en la interpretabilidad de sus resultados. El proyecto contempla, además, el diseño de un prototipo de visualización exploratoria que comunique los hallazgos del análisis, las predicciones del modelo y las variables asociadas al riesgo, con el propósito de que los resultados puedan ser leídos por actores educativos no especializados en ciencia de datos. De este modo, se busca aportar una ruta metodológica aplicada que articule predicción, interpretabilidad y comunicación visual como componentes complementarios para el análisis del abandono estudiantil en entornos LMS.

El documento se organiza de la siguiente manera. En el capítulo de Definición del Problema se delimita el fenómeno del abandono estudiantil en entornos LMS y se formula la pregunta de investigación. El capítulo de Objetivos establece el propósito general y las metas específicas del proyecto, junto con los resultados esperados. El Alcance precisa las fronteras del estudio, sus restricciones y las líneas que quedan planteadas como trabajo futuro. La Justificación expone la pertinencia del proyecto desde las perspectivas práctica, técnica y de viabilidad. El Marco de Referencia presenta los fundamentos teóricos y los antecedentes que sustentan la propuesta. El capítulo de Recursos describe los datos, las herramientas y los medios bibliográficos empleados. Finalmente, la Metodología detalla las actividades asociadas a cada objetivo específico.

2. Definición del Problema

En esta sección se delimita el problema central del proyecto: la predicción temprana del abandono estudiantil en entornos mediados por LMS, a partir de patrones observables de interacción, desempeño y trayectoria académica. En lugar de abordar la deserción únicamente como un resultado final, se propone entenderla como un proceso que puede manifestarse progresivamente mediante señales de baja participación, discontinuidad en el uso de la plataforma y cambios en el comportamiento digital del estudiante.

2.1. Planteamiento del Problema

La deserción estudiantil en educación superior constituye una problemática persistente con efectos académicos, sociales e institucionales. Su ocurrencia representa la interrupción de una trayectoria formativa antes de la obtención del título o la finalización del curso, con consecuencias asociadas a la pérdida de inversión económica y de tiempo, la disminución de oportunidades de movilidad social, el deterioro de indicadores institucionales de calidad y la reducción del capital humano disponible para la sociedad [1], [2], [3]. A nivel global, se estima que una proporción considerable de estudiantes universitarios no culmina sus estudios; en Estados Unidos, por ejemplo, cerca del 40 % de quienes ingresan a programas de pregrado no obtiene el título en un periodo de seis años [1]. En el caso de América Latina, aproximadamente el 50 % de la población entre 25 y 29 años que inició una carrera universitaria no logró completarla [2]. En particular, en Colombia, la deserción universitaria ha alcanzado históricamente cifras cercanas al 44,9 %, con niveles críticos en áreas como ingeniería y tecnología, donde se han reportado tasas superiores al 60 % [4].

La situación resulta más compleja en modalidades virtuales, a distancia o mediadas por plataformas digitales. En estos escenarios, la separación física entre docente y estudiante puede disminuir las oportunidades de acompañamiento directo, dificultar la detección temprana de señales de desconexión y aumentar la probabilidad de abandono cuando el estudiante reduce su participación en el entorno de aprendizaje [5]. De hecho, en cursos masivos abiertos en línea (MOOC) y plataformas *e-learning*, la literatura ha reportado tasas de abandono considerablemente superiores a las de la educación presencial, con casos que alcanzan porcentajes cercanos al 70 % o incluso al 90 %, dependiendo del tipo de curso, plataforma y definición de abandono empleada [5], [6].

En los entornos de aprendizaje virtual o mediados por Sistemas de Gestión de Aprendizaje (LMS), las plataformas registran de manera continua las interacciones de los estudiantes con los recursos educativos, las evaluaciones, los foros, los contenidos y las actividades del curso. Estos registros permiten observar señales de participación, continuidad, intensidad de uso y desempeño académico que pueden anteceder al retiro formal [6], [7]. Sin embargo, la sola disponibilidad de datos no garantiza su aprovechamiento para la toma de decisiones educativas; por el contrario, muchas instituciones continúan actuando de forma reactiva, cuando la pérdida de participación ya se ha convertido en retiro, fracaso académico o desvinculación definitiva [8].

Otro aspecto relevante es que, desde la perspectiva de la Analítica de Aprendizaje y la Minería de Datos Educativos, el comportamiento estudiantil en entornos LMS puede entenderse como el conjunto de patrones observables de interacción digital que reflejan cómo, cuándo, cuánto y con qué continuidad

un estudiante participa en el entorno virtual. Esto significa que se puede operacionalizar el comportamiento a partir de señales registradas por la plataforma, como frecuencia de acceso, número de clics, regularidad de interacción, tiempo desde la última actividad, entrega de evaluaciones, variación semanal de la participación y uso de recursos educativos, sin asumir que dichas variables midan directamente estados psicológicos como motivación o intención de abandono [6], [7], [9]. En este sentido, más que como un volumen acumulado de actividad, la baja interacción debe analizarse como parte de una trayectoria temporal, pues el riesgo de abandono puede intensificarse de manera progresiva y variar según el patrón previo del estudiante [5], [10]. Por ello, el problema consiste en representar adecuadamente las señales académicas, conductuales y temporales que permiten identificar patrones tempranos de riesgo. [11], [12].

2.2. Formulación del Problema

¿Cómo un modelo predictivo temprano e interpretable de aprendizaje automático, basado en variables académicas, conductuales y temporales puede identificar estudiantes en riesgo de abandono en entornos LMS y apoyar la toma de decisiones educativas mediante resultados explicables y visualizables?

2.2.1. Preguntas de sistematización

- ¿Qué variables académicas, conductuales y temporales disponibles en el dataset pueden identificarse y caracterizarse para establecer su pertinencia en el estudio del abandono estudiantil en un entorno LMS?
- ¿Qué variables derivadas de la interacción estudiantil en el LMS pueden construirse para caracterizar patrones de acceso, participación, continuidad, desempeño e inactividad?
- ¿Qué modelos supervisados de aprendizaje automático permiten predecir tempranamente el abandono estudiantil a partir de variables académicas, conductuales y temporales?
- ¿Qué modelo presenta el mejor equilibrio entre desempeño predictivo e interpretabilidad para identificar estudiantes en riesgo de abandono en entornos LMS?
- ¿Cómo pueden estructurarse los resultados del análisis exploratorio, las predicciones del modelo y las explicaciones asociadas al riesgo estudiantil en un prototipo de visualización que apoye la lectura educativa de los hallazgos?

3. Objetivos del Proyecto

3.1. Objetivo General

Desarrollar un modelo predictivo temprano e interpretable de aprendizaje automático, basado en variables académicas, conductuales y temporales, para identificar estudiantes en riesgo de abandono en entornos LMS y apoyar la toma de decisiones educativas mediante resultados explicables y visualizables.

3.2. Objetivos Específicos

- Identificar las variables académicas, conductuales y temporales disponibles en el conjunto de datos, mediante técnicas de preprocesamiento y análisis exploratorio, con el fin de establecer su pertinencia para el estudio del abandono en un entorno LMS.
- Derivar variables a partir de la interacción estudiantil en el LMS, tales como frecuencia de acceso, número de clics, regularidad de participación, variación temporal de la actividad y tiempo transcurrido desde la última interacción.
- Desarrollar y comparar modelos supervisados de aprendizaje automático para la predicción temprana del abandono estudiantil, mediante métricas de clasificación que permitan valorar su capacidad para identificar estudiantes en riesgo.
- Analizar la interpretabilidad del modelo seleccionado, identificando las variables que contribuyen en mayor medida a la clasificación de riesgo, con el fin de seleccionar la alternativa que presente el mejor equilibrio entre capacidad predictiva, explicación comprensible y utilidad educativa.
- Diseñar un prototipo de visualización que comunique de forma clara los resultados del análisis exploratorio, las predicciones del modelo y las explicaciones asociadas al riesgo estudiantil, con el fin de apoyar a los actores educativos en la toma de decisiones y el diseño de intervenciones oportunas.

3.3. Resultados Esperados

Con el desarrollo de este proyecto se espera obtener los siguientes productos:

1. Un dataset analítico documentado, que integre las variables académicas, conductuales y temporales de OULAD, junto con variables derivadas de la interacción estudiantil (frecuencia de acceso, regularidad de participación, variación temporal de actividad, tiempo desde la última interacción, entre otras), representando la trayectoria estudiantil como un proceso dinámico y no como un conjunto estático de atributos.
2. Una comparación sistemática de modelos supervisados de aprendizaje automático para la predicción temprana del abandono, evaluados mediante métricas de clasificación que consideren el posible desbalance entre clases, aportando una base técnica para valorar la utilidad de distintos enfoques en escenarios de alerta temprana educativa.

3. Un modelo predictivo seleccionado con análisis de interpretabilidad, que identifique las variables con mayor incidencia en la clasificación de riesgo y ofrezca explicaciones comprensibles para actores educativos, de modo que las predicciones funcionen como insumos para la reflexión pedagógica y no como decisiones automáticas.
4. Un prototipo de visualización exploratoria que comunique los patrones de participación, desempeño e inactividad, las predicciones del modelo y las variables asociadas al riesgo, facilitando la lectura de los hallazgos por parte de actores no especializados en ciencia de datos.

4. Alcance

El presente proyecto aplicado tiene como objetivo el desarrollo de un modelo predictivo temprano e interpretable de aprendizaje automático para identificar estudiantes en riesgo de abandono en entornos mediados por LMS, tomando como caso de estudio el *Open University Learning Analytics Dataset* (OULAD). El proyecto se centrará en el análisis de variables académicas, conductuales y temporales disponibles en el dataset, con el propósito de representar patrones de participación, desempeño, inactividad y trayectoria estudiantil dentro de un entorno virtual de aprendizaje.

Desde esta perspectiva, el proyecto abordará el abandono estudiantil como un fenómeno observable a partir de señales académicas y comportamentales registradas en el LMS, estudiando relaciones predictivas entre estas variables y el abandono registrado, sin asumir que dichas variables expliquen causalmente la deserción. Cabe precisar que la predicción de la reprobación queda fuera del alcance del presente proyecto y se plantea como una línea de trabajo futuro, en la cual podría evaluarse si el enfoque basado en señales conductuales y temporales aquí propuesto resulta más preciso que los modelos orientados a predecir el resultado académico final reportados en la literatura.

La incorporación de variables temporales se justifica dentro del alcance del proyecto, dado que estudios recientes han señalado que la importancia predictiva de los factores asociados al abandono puede variar a lo largo del tiempo. De hecho, en educación superior se ha reportado que variables académicas como los créditos acumulados y el número de cursos fallidos, junto con indicadores de actividad en Moodle, adquieren relevancia diferenciada según el momento de observación, lo que refuerza la necesidad de analizar el riesgo desde una perspectiva temporal y no únicamente como una clasificación final [13]. Con todo, este proyecto no desarrollará un modelo longitudinal institucional completo, sino una aproximación predictiva temprana basada en las ventanas y variables que puedan construirse a partir de OULAD.

El proyecto no contempla la implementación de un sistema institucional de alerta temprana en tiempo real, ni la integración directa con una plataforma LMS activa. Tampoco incluye la validación del modelo con estudiantes de una institución específica, la ejecución de intervenciones pedagógicas reales, ni la medición del efecto de dichas intervenciones sobre la reducción efectiva de la deserción. Todos estos aspectos deberán quedar planteados como líneas de trabajo futuro, especialmente si se busca adaptar el modelo a un contexto educativo colombiano o latinoamericano.

En cuanto a las restricciones, el estudio dependerá de las variables disponibles en OULAD, por lo que no será posible incorporar información no contenida en el dataset. Si bien OULAD ofrece una base robusta para el análisis de aprendizaje en entornos virtuales, sus datos corresponden a cursos de la Open University, de modo que los resultados no podrán generalizarse automáticamente a otras instituciones, modalidades educativas o contextos geográficos sin procesos adicionales de validación.

A este respecto, conviene reconocer que el abandono y la permanencia estudiantil son fenómenos multidimensionales que no pueden explicarse únicamente mediante registros de interacción en una plataforma. Estudios recientes en el contexto latinoamericano resaltan la influencia de factores académicos, motivacionales, socioeconómicos, familiares e institucionales en la retención universitaria, así como la necesidad de desarrollar modelos sensibles al contexto y a las condiciones locales de las instituciones [14]. Por ello, los resultados de este proyecto deberán interpretarse como una aproximación predictiva basada en datos disponibles en LMS, y no como una explicación integral de la deserción estudiantil.

Por otra parte, si bien el proyecto incorpora interpretabilidad para explicar las variables que inciden en la clasificación de riesgo, no realizará una evaluación exhaustiva de equidad algorítmica entre grupos de estudiantes. Este aspecto se reconoce como una limitación del alcance y deberá considerarse en trabajos futuros, especialmente si el modelo se adapta posteriormente a contextos institucionales reales.

5. Justificación

Ante la brecha entre la acumulación de registros digitales y su uso efectivo para el acompañamiento académico, resulta pertinente desarrollar estrategias analíticas que permitan transformar esas trazas de interacción en insumos oportunos para la gestión educativa. Dado que el problema del abandono estudiantil en entornos LMS ha sido caracterizado como un proceso progresivo y multidimensional, resulta pertinente explorar estrategias analíticas que permitan anticiparlo a partir de la información que las propias plataformas ya registran. Por este motivo, este proyecto propone un abordaje basado en datos existentes, sin requerir instrumentos adicionales de recolección ni intervención directa con los estudiantes, lo que favorece su aplicabilidad en contextos institucionales diversos.

En términos prácticos, la utilidad del proyecto se relaciona con la posibilidad de operacionalizar el comportamiento estudiantil mediante variables verificables dentro del LMS. Indicadores como la frecuencia de acceso, el número de clics, la regularidad de interacción, la entrega de evaluaciones, la variación semanal de la participación y el tiempo transcurrido desde la última actividad permiten representar distintos aspectos de la trayectoria estudiantil, concentrando así el análisis en patrones disponibles antes de que el abandono se consolide.

Ahora bien, en educación una predicción aislada tiene un valor limitado si no permite comprender qué variables contribuyen a la clasificación de riesgo. Por esta razón, el proyecto incorpora la interpretabilidad como parte del proceso de modelado, con el fin de evitar que los resultados se reduzcan a una salida técnica difícil de examinar desde una perspectiva educativa [11]. En la misma línea, la visualización de resultados permite comunicar de manera más clara los patrones identificados, las predicciones del modelo y las variables asociadas al riesgo, de modo que los hallazgos puedan ser revisados más allá del plano estrictamente algorítmico. La literatura sobre inteligencia de negocios en educación señala que los modelos predictivos adquieren mayor utilidad cuando sus resultados se integran en herramientas visuales que facilitan el seguimiento estudiantil y la priorización de apoyos académicos [15].

Desde el punto de vista de la viabilidad, un elemento que hace posible la ejecución del proyecto es el uso del dataset OULAD, una base de datos pública, anonimizada y ampliamente utilizada en investigaciones de analítica de aprendizaje y minería de datos educativa. OULAD contiene información demográfica, resultados de evaluación y registros de interacción diaria de los estudiantes con el entorno virtual de aprendizaje, lo que permite estudiar el comportamiento estudiantil desde una perspectiva académica, conductual y temporal [7]. Al tratarse de datos abiertos y anonimizados, el proyecto no requiere recolección primaria de información ni intervención directa con participantes, lo que permite concentrar el esfuerzo en las etapas de comprensión, preparación, modelado, evaluación, interpretación y comunicación de los resultados.

En la misma dirección, desde el punto de vista técnico existen herramientas y antecedentes suficientes para desarrollar el análisis propuesto. La literatura reciente ha mostrado la aplicación de modelos supervisados como regresión logística, árboles de decisión, *Random Forest*, *Gradient Boosting*, *XG-Boost* y otros algoritmos en problemas de predicción de rendimiento, abandono o riesgo académico en educación superior y entornos virtuales [16], [17], [18]. Con todo, el proyecto no pretende establecer explicaciones causales ni sustituir el juicio pedagógico o institucional; su alcance se limita a construir y evaluar un modelo predictivo interpretable, acompañado de un prototipo de visualización que facilite la lectura de los resultados obtenidos.

6. Marco de Referencia

6.1. Marco Teórico

El presente proyecto se fundamenta en la convergencia entre analítica de aprendizaje, minería de datos educativa y aprendizaje automático supervisado, aplicados a la identificación temprana de estudiantes en riesgo de abandono en entornos mediados por LMS. A continuación se precisan los conceptos centrales empleados a lo largo del documento.

Un Sistema de Gestión de Aprendizaje (LMS, *Learning Management System*) es una plataforma digital diseñada para administrar, distribuir y registrar actividades de enseñanza y aprendizaje en línea, incluyendo la gestión de cursos, la interacción con recursos educativos, la aplicación de evaluaciones y el registro de la actividad estudiantil [16]. En la literatura británica, este tipo de plataforma suele denominarse Entorno Virtual de Aprendizaje (VLE, *Virtual Learning Environment*), término empleado por la Open University para referirse a su plataforma institucional [7]. Dado que OULAD proviene de este contexto, el dataset utiliza la denominación VLE; sin embargo, desde el punto de vista funcional, la plataforma de la Open University opera como un LMS convencional, por lo que en este documento se emplea el término LMS como referencia general al tipo de plataforma y se conserva VLE únicamente cuando se hace referencia directa a las tablas o variables del dataset (por ejemplo, `studentVle`).

Por su parte, la predicción temprana se entiende como la capacidad de un modelo para identificar estudiantes en riesgo de abandono utilizando únicamente información disponible durante las primeras semanas del curso, es decir, antes de que el retiro o la inactividad se consoliden [10], [11]. Para lograr este propósito se recurre a ventanas temporales, definidas como periodos acotados del curso (por ejemplo, las primeras cuatro o seis semanas) dentro de los cuales se acumulan y calculan las variables predictoras [10]. La delimitación específica de estas ventanas se establecerá durante el análisis exploratorio del dataset.

Finalmente, la interpretabilidad se refiere a la capacidad de un modelo predictivo para ofrecer explicaciones comprensibles sobre los factores que sustentan sus predicciones [11]. En el marco de este proyecto, la interpretabilidad podrá abordarse de dos maneras: mediante modelos inherentemente explicables (como árboles de decisión o regresión logística) o bien mediante técnicas de explicabilidad *post-hoc* aplicadas a modelos de mayor complejidad, tales como SHAP (*SHapley Additive exPlanations*) o importancia de características [12]. La elección de la estrategia más adecuada dependerá del modelo seleccionado durante la fase de evaluación.

Estos conceptos operativos se inscriben en dos campos disciplinares complementarios. La analítica de aprendizaje se ocupa de la recolección, medición, análisis y comunicación de datos sobre los estudiantes y sus contextos, con el propósito de comprender y optimizar los procesos de aprendizaje [9], [16]. En entornos virtuales, esta perspectiva cobra especial relevancia, puesto que las plataformas LMS registran de manera continua las interacciones con los elementos del curso. Tales registros permiten observar comportamientos asociados a la frecuencia de acceso, la intensidad de participación, la regularidad de interacción, la entrega de actividades y el desempeño académico. Cabe señalar que, en este sentido, el comportamiento estudiantil no se interpreta como una medida directa de motivación, bienestar o intención de permanencia, sino como una representación observable de la forma en que el estudiante participa en el entorno digital [7].

Complementariamente, la minería de datos educativa se orienta al descubrimiento de patrones, relaciones y estructuras relevantes dentro de grandes volúmenes de datos educativos [16], [17]. Su aplicación permite analizar información proveniente de sistemas institucionales, plataformas LMS, resultados académicos y registros de interacción, con el fin de identificar factores asociados al rendimiento, la permanencia o el riesgo académico. Dentro de este campo, los problemas de predicción suelen formularse como tareas de clasificación, regresión, agrupamiento o detección de patrones, dependiendo del tipo de resultado que se desea analizar [16]. En el caso particular de este proyecto, el interés se concentra en una tarea supervisada de clasificación orientada a identificar estudiantes en riesgo de abandono.

En este contexto, el *Open University Learning Analytics Dataset* (OULAD) constituye una fuente relevante para el análisis de trayectorias estudiantiles en ambientes virtuales. OULAD contiene información demográfica, registros de matrícula, resultados de evaluación e interacciones diarias de estudiantes con el entorno virtual de aprendizaje. Su estructura permite relacionar características del estudiante, desempeño académico y comportamiento en el VLE, lo que lo convierte en una base adecuada para estudiar problemas de predicción de desempeño, abandono o participación estudiantil [7]. Una revisión sistemática reciente sobre estudios basados en este dataset identificó trabajos orientados a la predicción del desempeño, la identificación de estudiantes en riesgo y la predicción del compromiso estudiantil, aunque advierte desafíos relacionados con la calidad de los datos, la selección de variables, la complejidad de los modelos y su interpretabilidad [19].

Desde el punto de vista metodológico, el aprendizaje automático supervisado permite entrenar modelos a partir de datos históricos en los que se conoce previamente el resultado final del estudiante. A partir de estas observaciones, los algoritmos aprenden patrones que pueden ser utilizados para clasificar nuevos casos o estimar la probabilidad de pertenecer a una clase de riesgo. En la literatura sobre predicción educativa se han utilizado algoritmos como regresión logística, árboles de decisión, *Random Forest*, máquinas de soporte vectorial, *Gradient Boosting*, XGBoost, redes neuronales y modelos de ensamble [16], [17], [18]. La selección del modelo depende de su rendimiento predictivo y de su capacidad para ofrecer explicaciones útiles en contextos educativos. En este sentido, una revisión reciente sobre aprendizaje automático y profundo aplicados a la predicción de abandono en educación superior confirma que la regresión logística y los métodos basados en árboles (individuales y de ensamble) predominan en la literatura por su buen desempeño con datos estructurados [20]. Estos modelos difieren, sin embargo, en su transparencia: el mayor desempeño de los ensambles se obtiene a costa de su opacidad, lo que justifica recurrir a técnicas de interpretabilidad *post-hoc* en este proyecto.

Atendiendo a estas consideraciones, el presente proyecto propone un estudio comparativo entre modelos candidatos seleccionados con base en dos criterios complementarios: su desempeño reportado en la literatura sobre predicción de abandono y su compatibilidad con el análisis de interpretabilidad (obtenida de forma intrínseca o mediante técnicas *post-hoc* según el modelo). En primer lugar, se incluye la *regresión logística* como línea base interpretable: modela la probabilidad de que un estudiante pertenezca a la clase de riesgo como una función logística de una combinación lineal de las variables, lo que permite leer el signo y la magnitud del efecto de cada predictor directamente en sus coeficientes; estudios recientes sobre OULAD han mostrado que alcanza niveles de discriminación comparables a los de algoritmos más complejos [11]. En segundo lugar, se considera *Random Forest* como representante de los métodos de ensamble por *bagging*: combina un gran número de árboles de decisión entrenados sobre muestras aleatorias de los datos y promedia sus predicciones, lo que reduce la varianza del modelo, maneja variables de distinto tipo y proporciona medidas de importancia de características de forma nativa [6], [18]. En tercer lugar, se incorpora XGBoost como representante del *gradient boosting* basado en árboles: construye los árboles de manera secuencial, donde cada uno corrige los errores residuales de los anteriores mediante optimización por gradiente e incorpora regularización para controlar el sobreajuste, lo que lo ha consolidado como uno de los algoritmos de mayor adopción y rendimiento en predicción educativa [8], [16]. Como cuarta alternativa se incluye *LightGBM*, de la misma familia que XGBoost pero con crecimiento de árboles por hoja y discretización por histogramas que reducen su costo computacional y le dan ventaja en datasets de mayor volumen; su aplicación en predicción de abandono ha sido comparativamente menos explorada, lo que ofrece una oportunidad

para evaluar su desempeño frente a las alternativas ya consolidadas [20]. Finalmente, se contempla la posibilidad de incluir *TabNet*, un modelo de aprendizaje profundo diseñado para datos tabulares que incorpora mecanismos de atención secuencial para seleccionar las variables más relevantes en cada paso de decisión, lo que le confiere interpretabilidad intrínseca sin recurrir a técnicas *post-hoc* [21]. Su inclusión dependerá de la viabilidad técnica durante la fase de desarrollo y, en caso de no incorporarse, quedará planteada como una extensión natural del trabajo.

La utilidad de un modelo predictivo en este dominio, además de su desempeño, depende de que la predicción llegue a tiempo, de que pueda explicarse y de que pueda comunicarse a quienes toman decisiones. La primera condición concierne a la predicción temprana: un modelo entrenado con la información de todo el curso puede ser preciso, pero llega demasiado tarde para orientar acciones de apoyo, de ahí el énfasis en ventanas tempranas y en variables que capturan la dinámica de la participación (acumulados semanales, cambios en la actividad, tiempo desde la última interacción). La literatura reciente ha señalado, además, que la importancia de las variables predictoras puede cambiar a lo largo del tiempo y que los registros de actividad en LMS, combinados con información académica y demográfica, aportan señales relevantes para el seguimiento estudiantil [10], [13].

La segunda condición es la interpretabilidad, cuya utilidad práctica reside en permitir que docentes, tutores o responsables académicos no solo sepan qué estudiantes podrían estar en riesgo, sino también qué señales sustentan esa clasificación, lo que evita tratar el modelo como una “caja negra” y favorece una lectura pedagógica de sus resultados [11].

La tercera condición es la comunicación de los resultados, donde la visualización cumple un papel necesario para traducir los hallazgos del modelo en información comprensible. Los tableros, gráficos e interfaces exploratorias permiten organizar grandes volúmenes de datos educativos y comunicar patrones de riesgo, evolución de la participación, resultados de evaluación y explicaciones del modelo. Desde la perspectiva de la inteligencia de negocios aplicada a educación, la visualización facilita la identificación de tendencias, la priorización de apoyos y la toma de decisiones basada en evidencia [15]. En este proyecto, el prototipo de visualización se plantea como una aproximación exploratoria para comunicar los resultados del análisis y del modelo predictivo.

6.2. Antecedentes

Diversos trabajos han abordado la predicción del abandono o el rendimiento académico mediante técnicas de minería de datos educativa y aprendizaje automático. Estos antecedentes permiten reconocer avances relevantes, así como limitaciones que justifican la propuesta del presente proyecto.

Un punto de partida necesario para situar el campo es la revisión panorámica de los métodos y problemas de predicción educativa. Albreiki, Zaki y Alashwal desarrollaron una revisión sistemática que analiza la literatura sobre predicción del desempeño estudiantil, clasificando los tipos de datos utilizados, los problemas frecuentes del área y los algoritmos aplicados, entre ellos árboles de decisión, redes neuronales, máquinas de soporte vectorial y modelos de ensamble [16]. Una perspectiva complementaria la ofrece Córdova-Esparza y colaboradores, cuya revisión sistemática se centra específicamente en la intersección entre inteligencia de negocios, analítica predictiva y prevención de la deserción en educación superior, sintetizando evidencia sobre herramientas de visualización, tableros y modelos de aprendizaje automático aplicados a la identificación de estudiantes en riesgo [15]. Ambas revisiones coinciden en que, si bien existe un repertorio amplio de algoritmos con buen desempeño, persisten desafíos relacionados con la interpretabilidad de los resultados y la comunicación de hallazgos a actores educativos no técnicos.

Dentro de los estudios que abordan directamente el fenómeno del abandono en cursos en línea, Chen, Fang, Zhang y Xue realizaron una revisión sistemática sobre predicción de abandono en MOOC que identifica definiciones operativas del evento, factores asociados, métodos de extracción de características y métricas de evaluación, señalando además desafíos como el desbalance de clases y el modelado de trayectorias de aprendizaje [5]. Esta preocupación por la dimensión temporal del riesgo se profundiza en el trabajo de Da Silva, Eicher y Longo, quienes proponen un enfoque de modelado orientado a

supervivencia aplicado a OULAD, donde el abandono se concibe como un proceso cuyo riesgo evoluciona a partir de señales conductuales y de desempeño, en lugar de tratarse como un resultado estático [10].

Precisamente sobre OULAD se ha desarrollado una línea considerable de investigación empírica. Jha, Ghergulescu y Moldovan emplearon este dataset para predecir tanto el abandono como el resultado final de los estudiantes mediante técnicas de ensamble, aprendizaje profundo y regresión, reportando que las variables asociadas a la interacción con la plataforma alcanzaron un desempeño alto en términos de AUC [6]. El presente proyecto se diferencia de este antecedente en que busca reforzar el componente temprano, temporal e interpretable del análisis, además de orientar los resultados hacia una visualización exploratoria.

Más allá de OULAD, otros estudios han explorado la predicción de abandono a partir de registros de interacción en plataformas LMS distintas. Marcolino y colaboradores trabajaron con datos de logs de Moodle utilizando CatBoost, técnicas de balanceo y optimización multiobjetivo, mostrando la importancia de construir variables a partir de los registros de actividad y de atender problemas como el desbalance de clases y la generalización a cursos no vistos [18]. En una dirección similar, Vaarma y Li analizaron la predicción del abandono en educación superior finlandesa mediante datos demográficos, académicos y de Moodle, observando cómo la importancia relativa de los predictores cambia en función del tiempo desde la matrícula [13]. Estos hallazgos refuerzan la pertinencia de considerar la dimensión temporal como un eje de análisis, aspecto que el presente proyecto incorpora mediante el uso de ventanas temporales y variables acumuladas por semana.

Desde la perspectiva de la utilidad práctica del modelo, Shaikhanova y colaboradores desarrollaron un sistema de apoyo a decisiones para la identificación temprana de estudiantes en riesgo, enfatizando tres aspectos: predicción temprana, carga de trabajo docente e interpretabilidad. Su estudio muestra que un modelo útil en educación no debe evaluarse únicamente por su AUC o exactitud, sino también por su capacidad de generar alertas manejables y explicaciones comprensibles [11]. Este planteamiento es afín al enfoque del presente proyecto, donde la interpretabilidad y la comunicación visual de los resultados se conciben como componentes inseparables del proceso de modelado.

Por último, en el contexto latinoamericano se han desarrollado estudios que confirman la aplicabilidad de estas técnicas en entornos con particularidades propias. Kuz y Morales presentaron un estudio de caso sobre deserción universitaria en México desde la ciencia de datos educativa, resaltando el valor de las métricas y la visualización para analizar patrones institucionales [8]. Madrid Orrego y colaboradores, por su parte, aplicaron técnicas de minería de datos para identificar factores determinantes de la deserción en una universidad pública colombiana, utilizando árboles de decisión como herramienta de análisis [4]. Estos trabajos evidencian que, aunque los enfoques metodológicos son transferibles, su implementación en la región se ha orientado principalmente a la identificación de factores asociados, con menor énfasis en la predicción temprana, la interpretabilidad y la visualización integrada que propone el presente proyecto.

7. Recursos a Emplear

7.1. Recursos Humanos

Para el desarrollo del presente proyecto aplicado se contará con la participación de los estudiantes responsables del proyecto, Oriana Giraldo Arcia y Luis Javier Rubio Hernández, quienes estarán a cargo de la revisión bibliográfica, el procesamiento de datos, la construcción de variables, el entrenamiento de modelos, la evaluación de resultados, el análisis de interpretabilidad y el diseño del prototipo de visualización. Ambos son matemáticos con maestría en matemáticas y ocho años de experiencia cada uno en docencia y en los procesos administrativos y pedagógicos propios de la educación básica y superior.

La dirección académica del proyecto estará a cargo de Gerardo Mauricio Sarria Montemiranda, docente de planta de la Universidad y Director del Programa de Ingeniería de Sistemas y Computación de la Facultad de Ingeniería y Ciencias. Su vinculación institucional y su rol en el programa respaldan la supervisión metodológica del trabajo y la viabilidad de su ejecución.

El proyecto no se desarrollará en el marco de una empresa ni de una intervención institucional directa y tampoco contempla la vinculación de estudiantes reales, docentes o personal administrativo como participantes de investigación.

7.2. Ética y Datos

El proyecto utilizará como fuente principal el *Open University Learning Analytics Dataset* (OULAD), disponible públicamente en el portal del *Knowledge Media Institute* de *The Open University*, a través del enlace:

<https://analyse.kmi.open.ac.uk/open-dataset>

En cuanto a las condiciones de uso, el artículo que describe y acompaña al dataset fue publicado bajo una licencia *Creative Commons Attribution 4.0 International* (CC BY 4.0), la cual permite el uso, la distribución, la adaptación y la reproducción del material en cualquier medio o formato, siempre que se otorgue el crédito apropiado a los autores originales y a la fuente, se incluya un enlace a la licencia y se indique si se realizaron modificaciones¹. Adicionalmente, los archivos de metadatos asociados al dataset están cubiertos por la exención de dedicación al dominio público de Creative Commons (*Creative Commons Public Domain Dedication waiver*, CC0 1.0)². Estas condiciones habilitan el uso académico e investigativo del dataset en el presente proyecto, cumpliendo con la atribución correspondiente mediante la citación del artículo original.

De acuerdo con su descripción original, OULAD integra información de 22 presentaciones de cursos, 32.593 estudiantes, resultados de evaluación y más de diez millones de registros resumidos de clics en el VLE [7].

La estructura de OULAD se organiza en un conjunto de tablas relacionales que permiten vincular distintos niveles de información. Por una parte, incluye tablas asociadas a la oferta académica, como

¹Licencia disponible en: <http://creativecommons.org/licenses/by/4.0/>

²Disponible en: <http://creativecommons.org/publicdomain/zero/1.0/>

los módulos y sus presentaciones; por otra, contiene información de los estudiantes, su registro en los cursos, sus evaluaciones y su interacción con los recursos del entorno virtual. Esta organización permite construir variables que relacionan el perfil del estudiante, su trayectoria académica, su desempeño evaluativo y su comportamiento de participación en el VLE.

Para facilitar la comprensión de la estructura de los datos, la Figura 7.1 presenta el esquema relacional del dataset, donde se observan las tablas, sus conexiones y la procedencia de las variables utilizadas en el análisis.




FIGURA 7.1: Esquema relacional del dataset OULAD. Fuente: Open University Learning Analytics Dataset.

Desde el punto de vista ético, el uso de OULAD reduce los riesgos asociados al tratamiento de datos personales, dado que se trata de una base pública y anonimizada. El proyecto no recolectará datos directamente de estudiantes, no accederá a bases institucionales privadas ni trabajará con información que permita identificar individualmente a una persona, por lo que no requiere consentimiento informado ni involucra interacción directa con sujetos humanos.

No obstante, el uso de datos educativos para clasificar estudiantes en riesgo exige precauciones específicas. Los resultados del modelo no serán presentados como diagnósticos definitivos ni como explicaciones causales del abandono, sino como estimaciones predictivas basadas en patrones observables,

orientadas a apoyar el acompañamiento académico. Aunque el proyecto no realizará una evaluación exhaustiva de equidad algorítmica, este aspecto se considerará como una limitación y una línea de trabajo futuro [22].

Para mitigar riesgos éticos, se adoptarán las siguientes medidas:

- Utilizar únicamente la versión pública y anonimizada de OULAD, sin intentar reidentificar estudiantes, cursos ni docentes.
- Interpretar las predicciones como señales de apoyo para la toma de decisiones educativas, no como mecanismos de exclusión, sanción o decisión automática.
- Incorporar análisis de interpretabilidad para explicar las variables que inciden en la clasificación de riesgo.
- Reconocer las limitaciones del dataset y evitar generalizaciones a otros contextos educativos, institucionales o geográficos.

7.3. Recursos Bibliográficos y de Información

Los artículos consultados para la fundamentación del proyecto fueron obtenidos mediante fuentes de acceso público, revistas de acceso abierto, bibliotecas digitales académicas y recursos disponibles a través de las credenciales institucionales de la Pontificia Universidad Javeriana Cali – Biblioteca Cali.

Entre las fuentes de acceso público y abierto se consultaron artículos disponibles en revistas y plataformas como *Education Sciences*, *Informatics* y *Mathematics*, revistas internacionales arbitradas de acceso abierto publicadas por MDPI. También se utilizaron recursos disponibles en RSIS International, Revista LATAM, SciTePress Digital Library, PeerJ Computer Science e IEEE Xplore, según la disponibilidad de cada documento.

Adicionalmente, algunos artículos fueron consultados mediante inicio de sesión institucional con credenciales de la Pontificia Universidad Javeriana Cali – Biblioteca Cali. Este acceso permitió consultar documentos disponibles en bases y editoriales académicas como Springer Nature, Sage Journals, ScienceDirect y Taylor & Francis Online.

El uso de estas fuentes se limita a fines académicos y de investigación.

7.4. Otros Recursos

El desarrollo del proyecto se realizará utilizando Python como lenguaje principal de programación, ejecutado en scripts y entornos de *notebooks* como Jupyter Notebook o Google Colab. Para el procesamiento, análisis y modelado de datos se emplearán bibliotecas de uso estándar en ciencia de datos. A su vez, el análisis de interpretabilidad se apoyará en bibliotecas orientadas a la explicabilidad de modelos, como SHAP o similares, cuya selección se ajustará según las necesidades del proyecto.

En lo que respecta a la gestión del código fuente y el control de versiones, se utilizará Git con repositorio alojado en GitHub. Por su parte, el prototipo de visualización exploratoria se desarrollará mediante herramientas como Streamlit, Plotly Dash o una alternativa equivalente; la selección definitiva se realizará durante la fase de diseño del prototipo.

En cuanto a infraestructura computacional, el proyecto se ejecutará en equipos personales de los estudiantes. De ser necesario contar con capacidad de procesamiento adicional para el entrenamiento de modelos, se podrá recurrir a entornos en la nube como Google Colab Pro u otros servicios disponibles a través de la universidad.

8. Metodología

Este proyecto corresponde a un trabajo de tipo aplicado, con enfoque cuantitativo y diseño no experimental, ya que se construye un modelo predictivo a partir de datos previamente recolectados y anonimizados, sin manipulación de variables ni recolección primaria de información. Para su desarrollo se adopta la metodología CRISP-DM (*Cross-Industry Standard Process for Data Mining*), un marco ampliamente utilizado en proyectos de ciencia de datos tanto en el ámbito académico como en el profesional, lo que la hace pertinente para un ejercicio formativo orientado a la práctica laboral. Sus fases se articulan con los objetivos específicos planteados, de modo que cada objetivo aporta al avance progresivo del proceso.

Aunque no se formula como un objetivo específico, la fase inicial de comprensión del área antecede al trabajo con los datos y orienta decisiones conceptuales que condicionan todo el análisis posterior. Un ejemplo es la definición misma del abandono, que en este proyecto se aborda desde dos perspectivas complementarias: el retiro formal del curso, registrado en el campo `date_unregistration`, y el abandono implícito, entendido como la inactividad prolongada en la plataforma.

En términos de las fases de CRISP-DM, el objetivo específico 1 corresponde a la comprensión de los datos; el objetivo 2, a la preparación de los datos; el objetivo 3, al modelado; el objetivo 4, a la evaluación e interpretabilidad; y el objetivo 5, a una aproximación al despliegue mediante un prototipo de visualización.

8.1. Actividades por Objetivo Específico

8.1.1. Objetivo específico 1

Identificar las variables académicas, conductuales y temporales disponibles en el conjunto de datos, mediante técnicas de preprocesamiento y análisis exploratorio, con el fin de establecer su pertinencia para el estudio del abandono en un entorno LMS.

Para alcanzar este objetivo se realizarán las siguientes actividades:

- **A1.1.** Descargar el dataset OULAD desde su fuente oficial, revisar su estructura relacional y realizar la carga inicial de los datos en el entorno de trabajo seleccionado.
- **A1.2.** Explorar las variables disponibles en las tablas asociadas a información estudiantil, matrícula, evaluaciones, cursos, recursos del VLE e interacción, identificando valores faltantes, duplicados, inconsistencias y posibles registros atípicos que deban ser tratados antes del modelado.
- **A1.3.** Realizar un análisis exploratorio para describir la distribución de las variables académicas, conductuales y temporales, y a partir de este seleccionar las variables base que serán utilizadas para representar la participación, el desempeño, la inactividad y la trayectoria estudiantil.

8.1.2. Objetivo específico 2

Derivar variables a partir de la interacción estudiantil en el LMS, tales como frecuencia de acceso, número de clics, regularidad de participación, variación temporal de la actividad y tiempo transcurrido desde la última interacción.

Para alcanzar este objetivo se realizarán las siguientes actividades:

- **A2.1.** Integrar las tablas necesarias del dataset OULAD para relacionar información del estudiante, curso, evaluación e interacción con el VLE.
- **A2.2.** Definir ventanas temporales de análisis que permitan observar la participación estudiantil durante etapas tempranas del curso.
- **A2.3.** Construir variables agregadas de interacción, tales como número total de clics, cantidad de días activos, frecuencia de acceso y promedio de actividad por periodo.
- **A2.4.** Construir variables de continuidad e inactividad, tales como regularidad de participación, semanas sin actividad y tiempo transcurrido desde la última interacción.
- **A2.5.** Construir variables relacionadas con desempeño académico inicial, considerando entregas de evaluaciones, puntuaciones obtenidas y cumplimiento de actividades evaluativas.
- **A2.6.** Generar variables temporales que permitan representar cambios en la participación, disminución progresiva de actividad o variación de interacción entre periodos.
- **A2.7.** Consolidar un dataset final que contenga la variable objetivo y las variables predictoras seleccionadas y construidas.

8.1.3. Objetivo específico 3

Desarrollar y comparar modelos supervisados de aprendizaje automático para la predicción temprana del abandono estudiantil, mediante métricas de clasificación que permitan valorar su capacidad para identificar estudiantes en riesgo.

Para alcanzar este objetivo se realizarán las siguientes actividades:

- **A3.1.** Definir la variable objetivo del modelo a partir de la tabla `studentRegistration` del dataset OULAD. Se considerará como abandono el caso en que el campo `date_unregistration` contenga un registro, lo cual indica que el estudiante realizó un retiro voluntario del curso; los estudiantes sin registro en dicho campo se considerarán como no desertores. Adicionalmente, se explorará la posibilidad de identificar casos de abandono implícito, entendido como aquellos estudiantes que, sin haberse retirado formalmente, presentan inactividad prolongada en la plataforma según los registros de la tabla `studentVle`. Los criterios para definir el umbral de inactividad se establecerán durante el análisis exploratorio.
- **A3.2.** Dividir el dataset en conjuntos de entrenamiento y prueba mediante una partición estratificada que conserve la proporción de clases en ambos conjuntos, garantizando condiciones adecuadas para la evaluación del modelo.
- **A3.3.** Aplicar las transformaciones necesarias a las variables predictoras, tales como codificación de variables categóricas, normalización o escalamiento, según lo requiera cada algoritmo.
- **A3.4.** Analizar la distribución de la variable objetivo para detectar posibles desbalances entre las clases (estudiantes que abandonan frente a quienes no lo hacen). En caso de identificarse un desbalance relevante, se aplicarán y compararán estrategias para mitigarlo, tales como el ajuste de pesos por clase, técnicas de remuestreo (sobremuestreo de la clase minoritaria o submuestreo de la mayoritaria) o el ajuste del umbral de decisión. Estas estrategias se aplicarán únicamente sobre el conjunto de entrenamiento, con el fin de evitar fugas de información hacia el conjunto de prueba, y su efecto se valorará mediante métricas sensibles al desbalance, como la sensibilidad y el F1-score.

- **A3.5.** Entrenar los modelos supervisados de clasificación fundamentados en el marco teórico: regresión logística como línea base interpretable, *Random Forest* como representante de ensambles por *bagging*, XGBoost y LightGBM como representantes de *gradient boosting*, y, de ser viable, TabNet como alternativa de aprendizaje profundo para datos tabulares.
- **A3.6.** Evaluar y comparar el desempeño de los modelos entrenados mediante métricas como exactitud, precisión, sensibilidad, F1-score, matriz de confusión y AUC, identificando las fortalezas y limitaciones de cada alternativa para la etapa posterior de interpretabilidad.

8.1.4. Objetivo específico 4

Analizar la interpretabilidad del modelo seleccionado, identificando las variables que contribuyen en mayor medida a la clasificación de riesgo, con el fin de seleccionar la alternativa que presente el mejor equilibrio entre capacidad predictiva, explicación comprensible y utilidad educativa.

Para alcanzar este objetivo se realizarán las siguientes actividades:

- **A4.1.** Revisar el desempeño de los modelos candidatos considerando tanto métricas globales como métricas orientadas a la identificación de estudiantes en riesgo, con especial atención a la matriz de confusión, los falsos negativos y los falsos positivos.
- **A4.2.** Aplicar técnicas de interpretabilidad —en particular SHAP (*SHapley Additive exPlanations*)— a los modelos candidatos, con el fin de identificar las variables con mayor incidencia en las predicciones y comparar si los distintos modelos coinciden en los factores que consideran más relevantes para la clasificación de riesgo.
- **A4.3.** Seleccionar el modelo final con base en el equilibrio entre desempeño predictivo, interpretabilidad y utilidad para comunicar señales de riesgo académico, documentando los principales patrones asociados a la clasificación, tales como baja interacción, inactividad prolongada, desempeño inicial bajo o disminución de participación.

8.1.5. Objetivo específico 5

Diseñar un prototipo de visualización que comunique de forma clara los resultados del análisis exploratorio, las predicciones del modelo y las explicaciones asociadas al riesgo estudiantil, con el fin de apoyar a los actores educativos en la toma de decisiones y el diseño de intervenciones oportunas.

Para alcanzar este objetivo se realizarán las siguientes actividades:

- **A5.1.** Definir los elementos que deberá comunicar el prototipo de visualización (patrones de participación, desempeño, inactividad, predicción de riesgo e importancia de variables) y seleccionar la herramienta de desarrollo más adecuada de acuerdo con las posibilidades técnicas del proyecto.
- **A5.2.** Diseñar e implementar las visualizaciones exploratorias del prototipo, integrando la distribución de resultados académicos, la evolución temporal de la participación, las predicciones del modelo diferenciadas por nivel de riesgo y los elementos de interpretabilidad que permitan identificar las variables más influyentes en la clasificación.
- **A5.3.** Revisar la claridad, coherencia y utilidad educativa del prototipo, verificando que los resultados sean comprensibles para usuarios no especializados en ciencia de datos, y documentar sus componentes, limitaciones y posibles mejoras para trabajos futuros.

9. Cronograma de Actividades

El cronograma del proyecto se plantea para una ejecución de diez meses. Las actividades corresponden a las definidas en la metodología y se organizan de acuerdo con los cinco objetivos específicos del proyecto.

TABLA 9.1: Cronograma de actividades del proyecto

Código	Actividad	M1	M2	M3	M4	M5	M6	M7	M8	M9	M10
Objetivo específico 1: Identificar y caracterizar variables											
A1.1	Descarga del dataset OULAD, revisión de su estructura relacional y carga inicial de los datos.	X	X								
A1.2	Exploración de variables e identificación de valores faltantes, duplicados, inconsistencias y registros atípicos.		X								
A1.3	Análisis exploratorio y selección de las variables base (participación, desempeño, inactividad y trayectoria).		X	X							
Objetivo específico 2: Derivar variables de interacción											
A2.1– A2.2	Integración de las tablas del dataset y definición de ventanas temporales de análisis.			X							
A2.3– A2.5	Construcción de variables de interacción, continuidad e inactividad, y desempeño académico inicial.			X	X						
A2.6– A2.7	Generación de variables de tendencia temporal y consolidación del dataset final.				X	X					
Objetivo específico 3: Desarrollar y comparar modelos supervisados											
A3.1	Definición de la variable objetivo (retiro formal vía <code>date_unregistration</code>) y exploración de criterios de abandono implícito.					X					
A3.2– A3.3	División estratificada del dataset en entrenamiento y prueba, y transformación de las variables predictoras.					X					
A3.4	Detección y, en caso necesario, tratamiento de posibles desbalances de clases (pesos por clase, remuestreo o ajuste de umbral) sobre el conjunto de entrenamiento.					X	X				
A3.5	Entrenamiento y ajuste de hiperparámetros de los modelos candidatos.						X				
A3.6	Evaluación y comparación del desempeño con énfasis en la identificación de estudiantes en riesgo.						X	X			
Objetivo específico 4: Analizar interpretabilidad y seleccionar modelo											
A4.1	Revisión del desempeño con atención a la matriz de confusión, los falsos negativos y los falsos positivos.							X			
A4.2	Aplicación de SHAP y comparación de las variables relevantes para la clasificación de riesgo.							X	X		
A4.3	Selección del modelo final y documentación de los patrones de riesgo identificados.								X		
Objetivo específico 5: Diseñar prototipo de visualización											
A5.1	Definición de los elementos del prototipo y selección de la herramienta de desarrollo.								X		
A5.2	Diseño e implementación de las visualizaciones, predicciones por nivel de riesgo y elementos de interpretabilidad.									X	
A5.3	Revisión de la claridad y utilidad educativa del prototipo, y documentación de componentes, limitaciones y mejoras futuras.									X	X

Bibliografía

- [1] H. Huo et al., “Predicting Dropout for Nontraditional Undergraduate Students: A Machine Learning Approach,” *Journal of College Student Retention: Research, Theory & Practice*, vol. 24, n.º 4, págs. 1054-1077, 2023. DOI: [10.1177/1521025120963821](https://doi.org/10.1177/1521025120963821)
- [2] D. Opazo, S. Moreno, E. Álvarez-Miranda y J. Pereira, “Analysis of First-Year University Student Dropout through Machine Learning Models: A Comparison between Universities,” *Mathematics*, vol. 9, n.º 20, pág. 2599, 2021. DOI: [10.3390/math9202599](https://doi.org/10.3390/math9202599)
- [3] P. Karpagalakshmi, S. R. Dhanashree, M. A. Wahidh y A. Rajesh, “Predicting College Dropout Rates using Machine Learning: A Student Success Initiative,” en *2024 International Conference on Computing and Data Science (ICCDs)*, 2024, págs. 1-5. DOI: [10.1109/ICCDs60734.2024.10560384](https://doi.org/10.1109/ICCDs60734.2024.10560384)
- [4] D. M. Madrid Orrego, L. Figueroa Royero, H. Berrio Caballero, A. Y. Martínez Choles y J. A. Charris Rodríguez, “Minería de datos para la identificación de la Deserción Estudiantil en Universidades Públicas,” *LATAM Revista Latinoamericana de Ciencias Sociales y Humanidades*, vol. 4, n.º 2, págs. 1464-1476, 2023. DOI: [10.56712/latam.v4i2.697](https://doi.org/10.56712/latam.v4i2.697)
- [5] J. Chen, B. Fang, H. Zhang y X. Xue, “A Systematic Review for MOOC Dropout Prediction from the Perspective of Machine Learning,” *Interactive Learning Environments*, vol. 32, n.º 5, págs. 1642-1655, 2024. DOI: [10.1080/10494820.2022.2124425](https://doi.org/10.1080/10494820.2022.2124425)
- [6] N. I. Jha, I. Ghergulescu y A.-N. Moldovan, “OULAD MOOC Dropout and Result Prediction using Ensemble, Deep Learning and Regression Techniques,” en *Proceedings of the 11th International Conference on Computer Supported Education - Volume 2: CSEDU*, SciTePress, 2019, págs. 154-164. DOI: [10.5220/0007767901540164](https://doi.org/10.5220/0007767901540164)
- [7] J. Kuzilek, M. Hlosta y Z. Zdrahal, “Open University Learning Analytics dataset,” *Scientific Data*, vol. 4, pág. 170 171, 2017. DOI: [10.1038/sdata.2017.171](https://doi.org/10.1038/sdata.2017.171)
- [8] A. Kuz y R. Morales, “Ciencia de Datos Educativos y aprendizaje automático: un caso de estudio sobre la deserción estudiantil universitaria en México,” *Education in the Knowledge Society (EKS)*, vol. 24, e30080, 2023. DOI: [10.14201/eks.30080](https://doi.org/10.14201/eks.30080)
- [9] D. Duch, M. May y S. George, “Enhancing Predictive Analytics for Students’ Performance in Moodle: Insight from an Empirical Study,” *Journal of Data Science and Intelligent Systems*, 2024. DOI: [10.47852/bonviewJDSIS42023777](https://doi.org/10.47852/bonviewJDSIS42023777) dirección: <https://hal.science/hal-04776089>
- [10] R. da Silva, J. Eicher y G. Longo, “Temporal Dropout Risk in Learning Analytics: A Harmonized Survival Benchmark Across Dynamic and Early-Window Representations,” *arXiv preprint arXiv:2604.08870*, 2026. DOI: [10.48550/arXiv.2604.08870](https://doi.org/10.48550/arXiv.2604.08870)
- [11] A. Shaikhanova, O. Kuznetsov, K. Iklassova, A. Tokkuliyeve y L. Sugurova, “Interpretable Predictive Modeling for Educational Equity: A Workload-Aware Decision Support System for Early Identification of At-Risk Students,” *Big Data and Cognitive Computing*, vol. 9, n.º 11, pág. 297, 2025. DOI: [10.3390/bdcc9110297](https://doi.org/10.3390/bdcc9110297)

- [12] X. Jin, "A hybrid rule-based and machine learning framework for dynamic user profile construction in MOOC platforms: Integrating clickstream analysis and learner trajectory clustering," *International Journal of Mechanical Engineering Education*, vol. 0, n.º 0, págs. 1-22, 2026. DOI: [10.1177/03064190261439624](https://doi.org/10.1177/03064190261439624)
- [13] M. Vaarma y H. Li, "Predicting student dropouts with machine learning: An empirical study in Finnish higher education," *Technology in Society*, vol. 76, pág. 102474, 2024. DOI: [10.1016/j.techsoc.2024.102474](https://doi.org/10.1016/j.techsoc.2024.102474)
- [14] Y. Reina Marín et al., "Data Mining to Identify Factors Associated with University Student Retention," *Informatics*, vol. 13, n.º 4, pág. 50, 2026. DOI: [10.3390/informatics13040050](https://doi.org/10.3390/informatics13040050)
- [15] D.-M. Córdova-Esparza et al., "Predicting and Preventing School Dropout with Business Intelligence: Insights from a Systematic Review," *Information*, vol. 16, n.º 4, pág. 326, 2025. DOI: [10.3390/info16040326](https://doi.org/10.3390/info16040326)
- [16] B. Albreiki, N. Zaki y H. Alashwal, "A Systematic Literature Review of Student Performance Prediction Using Machine Learning Techniques," *Education Sciences*, vol. 11, n.º 9, pág. 552, 2021. DOI: [10.3390/educsci11090552](https://doi.org/10.3390/educsci11090552)
- [17] J. Niyogisubizo, L. Liao, E. Nziyumva, E. Murwanashyaka y P. C. Nshimyumukiza, "Predicting student's dropout in university classes using two-layer ensemble machine learning approach: A novel stacked generalization," *Computers and Education: Artificial Intelligence*, vol. 3, pág. 100066, 2022. DOI: [10.1016/j.caeai.2022.100066](https://doi.org/10.1016/j.caeai.2022.100066)
- [18] M. Rebelo Marcolino et al., "Student dropout prediction through machine learning optimization: insights from moodle log data," *Scientific Reports*, vol. 15, pág. 9840, 2025. DOI: [10.1038/s41598-025-93918-1](https://doi.org/10.1038/s41598-025-93918-1)
- [19] L. Jin, Y. Wang, H. Song y H. J. So, "Predictive Modelling with the Open University Learning Analytics Dataset (OULAD): A Systematic Literature Review," en *Artificial Intelligence in Education. Posters and Late Breaking Results, Workshops and Tutorials, Industry and Innovation Tracks, Practitioners, Doctoral Consortium and Blue Sky*, ép. Communications in Computer and Information Science, vol. 2150, Cham: Springer, 2024. DOI: [10.1007/978-3-031-64315-6_46](https://doi.org/10.1007/978-3-031-64315-6_46)
- [20] B. Duro, A. Gomes, F. B. Correia, A. R. Borges y J. Bernardino, "Machine Learning and Deep Learning for Dropout Prediction in Higher Education: A Review," *Computers*, vol. 15, n.º 3, pág. 164, 2026. DOI: [10.3390/computers15030164](https://doi.org/10.3390/computers15030164)
- [21] S. Ö. Arik y T. Pfister, "TabNet: Attentive Interpretable Tabular Learning," *Proceedings of the AAAI Conference on Artificial Intelligence*, vol. 35, n.º 8, págs. 6679-6687, 2021. DOI: [10.1609/aaai.v35i8.16826](https://doi.org/10.1609/aaai.v35i8.16826)
- [22] M. Verger, S. Lallé, F. Bouchet y V. Luengo, "Is Your Model 'MADD' ? A Novel Metric to Evaluate Algorithmic Fairness for Predictive Student Models," en *Proceedings of the 16th International Conference on Educational Data Mining*, Bengaluru, India: International Educational Data Mining Society, 2023, págs. 91-102. DOI: [10.5281/zenodo.8115786](https://doi.org/10.5281/zenodo.8115786)