

Auditoría de OULAD para el análisis de cinco ventanas temporales

Oriana Giraldo Arcia

Luis Javier Rubio Hernández

Proyecto Aplicado de Ciencia de Datos, PUJ Cali
Revisión técnica: 10 de septiembre de 2026

1 Propósito y alcance de la auditoría

La preparación de un modelo de abandono requiere establecer qué representan las filas, cómo se relacionan las fuentes y cuáles observaciones permiten reconstruir una trayectoria temporal. En este sentido, el estudio auditó las siete tablas CSV disponibles en la carpeta de datos, como parte del objetivo específico 1 y de la fase de comprensión de los datos de CRISP-DM. La revisión corresponde al notebook `01_carga_exploracion.ipynb`; sus resultados se obtuvieron mediante una ejecución nueva y no mediante la reutilización de salidas históricas.

El descriptor de OULAD identifica información de matrícula, evaluaciones e interacciones agregadas con recursos virtuales [1]. El presente informe examina su consistencia en los archivos locales. La comprobación de huellas SHA-256 permite reconocer los archivos utilizados y verificar que se conservaron intactos durante el procesamiento; no sustituye una certificación de procedencia.

2 Estructura y unidad de análisis

Se verificaron 32 593 inscripciones correspondientes a 28 785 personas, 7 módulos y 22 combinaciones de módulo y presentación. La inscripción se identifica mediante la clave compuesta de estudiante, módulo y presentación. Se encontraron 3 538 personas con más de una inscripción; por ello, el tamaño de la tabla no debe presentarse como número de estudiantes distintos.

Tabla 1: Dimensiones verificadas de las fuentes locales.

Tabla	Filas	Columnas
courses	22	3
assessments	206	6
vle	6 364	6
studentInfo	32 593	12
studentRegistration	32 593	5
studentAssessment	173 912	5
studentVle	10 655 280	6

La relación entre las tablas se comprobó sobre sus claves completas. Las evaluaciones se enlazaron por identificador antes de verificar su inscripción y los recursos se contrastaron conjuntamente con el módulo y la presentación. Todas las nueve verificaciones referenciales exportadas registraron cero casos sin correspondencia. Las uniones de la base se validaron como uno a uno para información y matrícula, y muchos a uno para el calendario de la presentación.

3 Registros repetidos y sensibilidad del volumen

Las claves de las tablas de entidades y de entregas resultaron únicas. En el log VLE se encontraron repeticiones exactas y repeticiones de la combinación estudiante, módulo, presentación, recurso y día. Estos campos no incluyen un identificador de sesión que permita explicar el origen de cada repetición. Por ello, se retiró la afirmación de que corresponden necesariamente a sesiones separadas.

Tabla 2: Filas adicionales a la primera ocurrencia de cada combinación.

Tabla	Exactos adicionales	Repetidos de clave
courses	0	0
assessments	0	0
vle	0	0
studentInfo	0	0
studentRegistration	0	0
studentAssessment	0	0
studentVle	787 170	2 195 960

El procesamiento principal conserva las filas originales. La Tabla 3 presenta la alternativa de retirar repeticiones exactas dentro de cada ventana inclusiva de días 0 a t . Los totales corresponden a toda la actividad registrada en esas fechas, antes de restringirla a la población elegible; por ello, no equivalen a los totales de los conjuntos analíticos. La reducción se sitúa aproximadamente entre 3,27 y 3,50 por ciento. Se trata de una sensibilidad del volumen, no de evidencia de que la deduplicación represente la fuente verdadera ni de una evaluación de su impacto predictivo.

Tabla 3: Sensibilidad de los clics en cada ventana, sobre la fuente completa.

Corte	Clics originales	Sin exactos	Reducción (%)
7	2 218 326	2 140 648	3,50
14	4 047 355	3 906 767	3,47
28	7 945 783	7 685 825	3,27
42	10 656 511	10 303 183	3,32
56	13 256 804	12 815 335	3,33

4 Faltantes, rangos y fechas

La ausencia de una fecha de retiro se distingue de un faltante de matrícula: la primera se utiliza para describir ausencia de retiro registrado; la segunda impide establecer directamente la elegibilidad al corte. Asimismo, la ausencia de puntaje no significa que no exista una entrega. La Tabla 4 explicita los denominadores de cada campo.

Tabla 4: Faltantes respecto del total de filas de cada tabla.

Tabla	Campo	Ausentes	Porcentaje
assessments	date	11	5,34
vle	week_from	5 243	82,39
vle	week_to	5 243	82,39
studentInfo	imd_band	1 111	3,41
studentRegistration	date_registration	45	0,14
studentRegistration	date_unregistration	22 521	69,10
studentAssessment	score	173	0,10

No se encontraron puntajes fuera de 0 a 100, clics no positivos ni valores inválidos de la bandera de reconocimiento de evaluaciones. La revisión de pesos se exportó separando evaluaciones continuas y exámenes, sin imponer una suma de 200 como regla universal. Las fechas negativas se conservaron porque representan acontecimientos anteriores al inicio y requieren interpretación temporal, no eliminación automática.

Tabla 5: Hallazgos de fechas y reconocimiento de entregas.

Verificación	Casos
Matrículas sin fecha	45
Matrículas después del día 28	16
Retiros después del final	1
Entregas anteriores al día 0	2 057
Entregas reconocidas de otra presentación	1 909
Registros VLE antes de matrícula	0
Registros VLE después del retiro	29 440
Entregas después del retiro	601

Los registros posteriores al retiro documentan una discrepancia entre las fechas de actividad y la fecha administrativa. No permiten determinar si se trata de demoras de registro, acceso posterior u otro proceso. El análisis predictivo debe proteger su secuencia temporal y no utilizar estas observaciones para describir señales anteriores a un retiro ya ocurrido. Tampoco se atribuyó automáticamente un mecanismo MAR o MNAR a los faltantes.

5 Definición administrativa del retiro

La distribución por fechas conserva el día 28 como referencia de auditoría. La elegibilidad se recalcula separadamente para los cinco cortes 7, 14, 28, 42 y 56 en el segundo informe; no se aplica este desglose histórico como filtro común.

La presencia de fecha de retiro se observó en 10 072 de 32 593 inscripciones (30,90 %). Esta proporción describe la fuente completa. Incluye eventos anteriores al inicio y al corte de predicción, por lo que no es la prevalencia del retiro futuro.

Tabla 6: Distribución administrativa del retiro.

Momento	Inscripciones	Porcentaje de la fuente
Antes del inicio	2 678	8,22
Después del día 28	5 017	15,39
Día 28	15	0,05
Días 0 a 27	2 362	7,25
Sin fecha de retiro	22 521	69,10

Tabla 7: Contraste de fecha de retiro y resultado final; 0 = no, 1 = sí.

Fecha presente	Distinction	Fail	Pass	Withdrawn
0	3 024	7 043	12 361	93
1	0	9	0	10 063

Se identificaron 102 discordancias: 93 inscripciones con resultado Withdrawn carecen de fecha de retiro y nueve con fecha de retiro tienen resultado Fail. Estas diferencias se exportaron para revisión. La etiqueta administrativa no se reemplazó por el resultado final ni se interpretó como evidencia suficiente del motivo voluntario del retiro.




Figura 1: Conteos de la fuente completa. El día 28 se mantiene separado de los eventos futuros.

6 Conclusiones y productos de la fase

La estructura relacional permite integrar las fuentes sin pérdidas en las claves auditadas. Sin embargo, la interpretación temporal exige distinguir retiros ya ocurridos, resultados finales discordantes y disponibilidad de las evaluaciones. El log contiene repeticiones cuya causa no es identificable en los archivos; conservar el volumen original constituye una decisión de procesamiento documentada y su efecto se acompaña de un escenario de sensibilidad.

La fase entrega una base de auditoría, un panel diario de clics y entregas con metadatos. Las tablas completas, las huellas de archivos y las comprobaciones de integridad se exportan junto con el notebook. Estos productos sustentan la preparación de variables; no acreditan todavía la validez de un clasificador ni el desempeño de un sistema de alerta temprana.

7 Distribución temporal del retiro

La figura presenta las 10 072 inscripciones con fecha de retiro de toda la fuente. Los 2 678 retiros preinicio no son eventos futuros de las ventanas examinadas; este denominador no debe mezclarse con la población filtrada por matrícula.




Figura 2: Distribución de fechas de retiro; líneas en el inicio y en los cortes 7, 14, 28, 42 y 56.

Referencias

- [1] Jakub Kuzilek, Martin Hlosta, and Zdenek Zdrahal. Open university learning analytics dataset. *Scientific Data*, 4:170171, 2017. DOI: 10.1038/sdata.2017.171.