

Ingeniería de variables en cinco cortes temporales

Oriana Giraldo Arcia

Luis Javier Rubio Hernández

Proyecto Aplicado de Ciencia de Datos, PUJ Cali

Revisión técnica: 10 de septiembre de 2026

1 Propósito y protocolo temporal

El análisis de varias ventanas permite examinar la disponibilidad y el significado de los indicadores conforme avanza una presentación. Esta fase de preparación de datos, correspondiente al segundo objetivo específico, construye una definición uniforme para los días 7, 14, 28, 42 y 56. El protocolo fue adoptado para esta versión por autorización del usuario y se registra en `decision_temporal.json`; este registro no constituye una aprobación institucional adicional.

La unidad continúa siendo la inscripción de una persona en un módulo y una presentación de OULAD [1]. Para un corte t , se incluyen las inscripciones con fecha conocida de matrícula $r_i \leq t$, sin retiro administrativo $u_i \leq t$ y cuyo final de presentación L_i es posterior al corte. Las fechas de retiro ausentes se interpretan como ausencia de retiro registrado. La etiqueta corresponde a

$$Y_i(t) = \mathbf{1}\{t < u_i \leq L_i\}.$$

Un retiro ocurrido exactamente en el día del corte se excluye de la población en riesgo. La observación abarca los días $0, 1, \dots, t$, incluidos ambos extremos; contiene $t + 1$ días de calendario. Los antecedentes anteriores al inicio se calculan separadamente. Se supone disponibilidad al cierre del día de los registros de interacción y entrega, y disponibilidad previa del calendario de evaluación. Los archivos no permiten verificar retrasos de publicación ni revisiones históricas del calendario.

El horizonte llega hasta el final de cada presentación; su duración cambia entre cortes y cursos. Por tanto, la comparación no mantiene un horizonte de seguimiento de longitud fija. La etiqueta identifica retiro administrativo registrado y no demuestra su carácter voluntario ni equivale automáticamente a *Withdrawn*. Las discordancias documentadas en la auditoría permanecen como limitación de la fuente.

2 Población elegible y cambio de composición

Tabla 1: Población y evento propios de cada corte; el porcentaje usa inscripciones elegibles.

Corte	Inscripciones	Personas	Retiros futuros	Porcentaje
7	29 076	26 030	6 632	22,81
14	28 054	25 220	5 580	19,89
28	27 515	24 826	5 012	18,22
42	27 005	24 491	4 500	16,66
56	26 506	24 105	3 998	15,08

La disminución de la población refleja principalmente retiros ya ocurridos; también existen nuevas matrículas entre cortes. En consecuencia, las filas de cortes distintos no son observaciones independientes ni representan exactamente la misma población. La menor prevalencia posterior no demuestra una mejora educativa: se modifica la población en riesgo y se acorta el seguimiento. Los flujos secuenciales y los denominadores por módulo y presentación se conservan en las tablas exportadas.

Tabla 2: Cambio de composición entre cortes consecutivos.

Desde	Hasta	Comunes	Salen	Entran
7	14	28 019	1 057	35
14	28	27 477	577	38
28	42	27 001	514	4
42	56	26 503	502	3

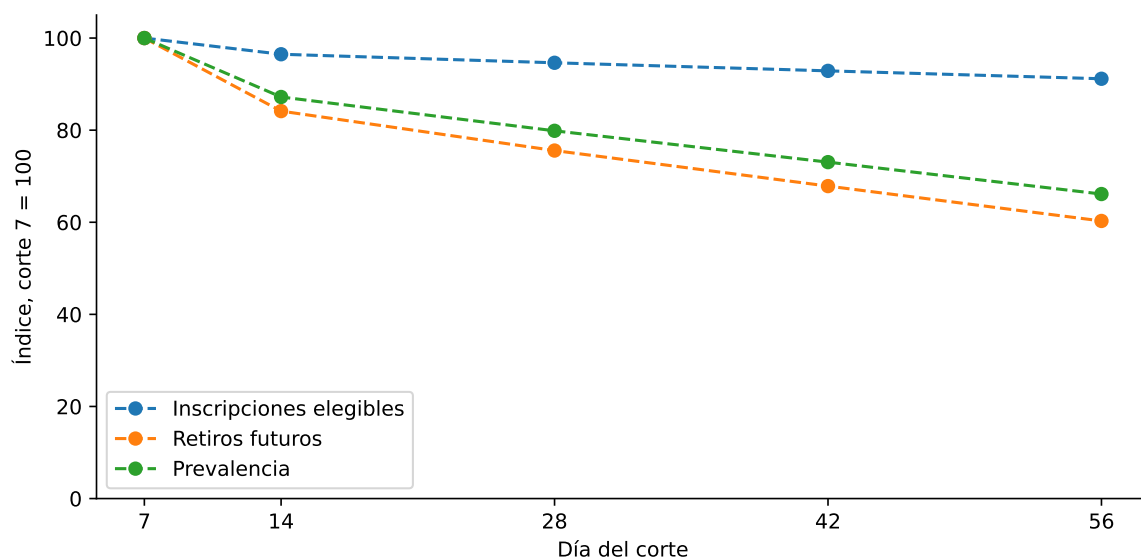


Figura 1: Inscripciones elegibles, retiros futuros y prevalencia: índice con corte 7 igual a 100. Las líneas unen poblaciones distintas; no son trayectorias de una cohorte.

3 Construcción y disponibilidad de indicadores

La actividad se resume mediante volumen de clics, días activos, frecuencia relativa, recencia y variabilidad de los totales diarios. Un día activo contiene al menos un clic; la proporción de días activos usa $t + 1$ como denominador. Esta normalización facilita una lectura temporal, pero no corrige la menor exposición de las matrículas posteriores al inicio. Se exporta adicionalmente el número de días matriculados dentro de la ventana para identificar esta condición. El número de filas VLE no se denomina número de sesiones.

La recencia es la diferencia entre el corte y el último día activo; se conserva ausente cuando no existe actividad en la ventana. El coeficiente de variación emplea la desviación estándar muestral de los totales diarios, incluidos los ceros, dividida por su media. También se cuentan semanas completas desde el día 0 y se omite el bloque final incompleto. Estos indicadores describen conductas observables; los clics no constituyen una medición directa de motivación.

La tendencia compara bloques contiguos de igual longitud que terminan en el corte. Para $s = 7$ o $s = 14$, se calcula

$$T_{i,s}(t) = \log \left(\frac{1 + \sum_{d=t-s+1}^t c_{id}}{1 + \sum_{d=t-2s+1}^{t-s} c_{id}} \right).$$

El término 1 permite razones finitas cuando un solo bloque tiene cero clics. Si ambos bloques son cero, la tendencia se conserva ausente; tampoco se calcula cuando existen menos de $2s$ días de historia. De este modo, la tendencia de siete días no está disponible en el corte 7 y la de catorce días solo se calcula desde el corte 28.

La inactividad acumulada y la ausencia de clics en los últimos 7, 14 o 28 días se conservan como indicadores complementarios. Una ventana reciente sin historia suficiente se representa como no observable, no como actividad ni como inactividad. Ninguna de estas banderas sustituye la etiqueta administrativa; su interpretación depende del calendario y de las oportunidades de participación.

Las entregas incluyen evaluaciones distintas de *Exam*, sin reconocimiento de otra presentación (*banked*), observadas entre 0 y t . Se distinguen las evaluaciones programadas hasta el corte y cuántas de ellas ya fueron entregadas; estas últimas pueden haberse entregado antes del inicio. La proporción entregada no mide puntualidad y queda ausente cuando no hay evaluaciones programadas. Los puntajes y su disponibilidad se conservan únicamente para auditoría, porque la fecha de entrega no acredita la fecha de publicación de la nota.

Tabla 3: Disponibilidad y exposición en la población elegible; conteos de inscripciones.

Corte	Sin actividad	Sin evaluación programada	Con entregas	Matrícula después de 0
7	5 316	29 076	772	140
14	2 551	26 765	3 226	173
28	1 203	4 988	19 849	208
42	918	2 426	22 276	210
56	765	2 407	22 812	212

En el corte 7 ninguna inscripción tiene evaluaciones con vencimiento entre 0 y 7, aunque 772 ya presentan entregas. Por ello, ausencia de entregas y falta de cumplimiento no son equivalentes. En el corte 28 persisten 4 988 inscripciones sin evaluación programada y en el corte 56 son 2 407; la ampliación de la ventana no elimina toda la heterogeneidad del calendario.

4 Enlace con la versión anterior y productos

La versión anterior del corte 28 observaba actividad hasta el día 27. La versión actual incorpora también el día 28 y mantiene las 27 515 inscripciones elegibles. Esta modificación explica cambios de cifras sin atribuirlos a alteraciones de las fuentes.

Tabla 4: Efecto de incluir el día 28 en las mismas inscripciones.

Indicador	Anterior	Actual	Inscripciones con cambio
Clics	7 603 586	7 766 285	7 993
Entregas	22 870	23 136	263

Se exportan conjuntos separados de datos auditables, predictores y etiquetas para cada corte; las claves se conservan para vincularlos, sin convertir el identificador de estudiante en predictor. El diccionario documenta 26 indicadores candidatos y separa las variables de contexto. La tabla apilada tiene una fila por inscripción y corte, no por persona. La intersección de los cinco conjuntos contiene 26 429 inscripciones y se utiliza únicamente para una sensibilidad retrospectiva.

Los productos permiten continuar con un protocolo predictivo común. El ajuste de imputación, escalado, selección y cualquier remuestreo deberá realizarse dentro del entrenamiento de cada partición [2]. Esta fase no entrenó clasificadores, no seleccionó una ventana óptima y no ofrece evidencia de desempeño fuera de muestra. Antes de modelar deberán fijarse la generalización buscada y la separación por personas o presentaciones; una persona presente en varios cortes no debe contaminar conjuntos de entrenamiento y evaluación.

5 Notación y definición de la tarea temporal

El día 0 es el inicio de la presentación; las fechas negativas son anteriores a ese origen. La unidad i es la terna de persona, módulo y presentación. Para cada corte t , $n_t = t + 1$ es la longitud inclusiva del calendario observado, r_i es la fecha de matrícula, u_i la fecha de retiro cuando existe y L_i el final según la convención operativa basada en la longitud registrada de la presentación. La ventana principal es $\{0, \dots, t\}$ y el horizonte futuro es $(t, L_i]$; los antecedentes preinicio se construyen separadamente.

Tabla 5: Guía de símbolos; los índices de modelos se definen localmente en su formulación.

Símbolo en las ecuaciones	Significado
i	Inscripción: persona, módulo y presentación
d, t	Día relativo al inicio y corte de predicción
n_t	Número de días observados: $t+1$
r_i, u_i, L_i	Matrícula, retiro y final de presentación
$c_{id}, A_i(t)$	Clics diarios y conjunto de días activos
V_i, k_i, q_i, m_i	Volumen, días activos, proporción activa e intensidad
$N(t), E(t), \pi(t)$	Inscripciones elegibles, eventos futuros y prevalencia
$Y_i(t)$	Evento binario posterior al corte y hasta el final
$p(\mathbf{x}), \tau$	Probabilidad condicional y umbral de clasificación
ϕ_j	Contribución de Shapley en una escala y referencia fijadas

$$\mathcal{E}(t) = \{i : r_i \text{ conocida}, r_i \leq t, (u_i \text{ ausente o } u_i > t), L_i > t\}, \quad (1)$$

$$N(t) = |\mathcal{E}(t)|, \quad Y_i(t) = \mathbf{1}\{t < u_i \leq L_i\}, \quad (2)$$

$$E(t) = \sum_{i \in \mathcal{E}(t)} Y_i(t), \quad \pi(t) = E(t)/N(t). \quad (3)$$

La función $\mathbf{1}$ vale uno cuando se cumple su condición y cero en otro caso; en particular, una fecha ausente no genera evento. Las barras $|\cdot|$ representan el número de elementos de un conjunto. La clase negativa significa ausencia de retiro registrado dentro del horizonte, no éxito académico ni permanencia acreditada. Los retiros del día del corte ya ocurrieron y quedan excluidos. El horizonte disminuye con t y varía entre presentaciones; la comparación mantiene reglas, no una misma duración de seguimiento.

Sean c_{id} los clics totales del día d y $A_i(t) = \{d \in [0, t] : c_{id} > 0\}$. El volumen, los días activos, la proporción activa y la intensidad se definen como

$$V_i(t) = \sum_{d=0}^t c_{id}, \quad k_i(t) = |A_i(t)|, \quad q_i(t) = \frac{k_i(t)}{n_t}, \quad m_i(t) = \frac{V_i(t)}{k_i(t)} \quad (k_i(t) > 0). \quad (4)$$

La recencia es $t - \max A_i(t)$ y su versión relativa divide por n_t ; ambas permanecen ausentes cuando no hay actividad. El CV de intensidad activa es la desviación estándar muestral de los clics en $A_i(t)$ dividida por su media; requiere $k_i(t) \geq 2$. El CV de calendario conserva los ceros. Para abreviar, con $n = n_t$, $k = k_i(t)$ y $q = k/n$,

$$CV_{cal}^2 = \frac{n}{n-1} \left[\frac{1-q}{q} + \frac{k-1}{kq} CV_{act}^2 \right], \quad k \geq 2. \quad (5)$$

La identidad se obtiene al descomponer la suma de cuadrados de los días activos como $(k-1)s_{act}^2 + km^2$ y usar la media de calendario qm . El primer término recoge la inactividad y el segundo la dispersión de intensidad; solo con intensidad constante se reduce a una función de q . Ningún CV se presenta como evidencia independiente de la frecuencia por el solo hecho de tener otro nombre.

El sumando 1 de la tendencia permite cocientes finitos con un bloque nulo. Se trata de un suavizado: intercambiar los bloques invierte exactamente el signo, pero escalar los conteos no conserva necesariamente el valor. Ambos bloques nulos se representan como no observables. La tendencia de siete días requiere $t \geq 13$ y la de catorce $t \geq 27$; 14 y 28 son los primeros cortes elegidos que cumplen esas condiciones, no los primeros matemáticamente posibles.

6 Selección de indicadores y diferencias respecto del anteproyecto

El conteo `n_registros_vle` mide filas originales por inscripción en $[0, t]$, sin identificar sesiones. Su granularidad y sus repeticiones no están explicadas por la fuente. Se conserva para auditoría y se retira del conjunto predictivo principal. Esta decisión evita atribuir a una frecuencia de registro un significado educativo que no ha sido verificado; el VIF documentado aporta una razón adicional de redundancia, pero no es por sí solo una regla universal de exclusión.

La diversidad de recursos y tipos de actividad no se construye en esta versión. El conjunto se delimita a volumen, continuidad, recencia, variación temporal y participación evaluativa, conservando el diseño de indicadores examinado y añadiendo la comparación entre ambos CV. Esta delimitación no demuestra falta de utilidad de diversidad: su evaluación requeriría integrar el catálogo de recursos y considerar oportunidades diferentes entre módulos. La familia se mantiene en el marco como posibilidad derivable, con esta exclusión explícita de la implementación actual.

La actividad A3.1 del anteproyecto interpreta la fecha como retiro voluntario y propone explorar abandono implícito. Los archivos permiten ubicar la baja pero no demostrar su motivo; por ello, se adopta el retiro registrado futuro y se mantiene la inactividad como indicador complementario. La predicción de inactividad en un periodo futuro sería otra tarea, no necesariamente circular; no se adopta como segunda etiqueta en esta versión. A2.5 contempla puntajes, que se conservan solo para auditoría porque falta su fecha de publicación. Estas diferencias y la restricción de población al corte deben ratificarse académicamente; la autorización de trabajo no constituye un acta institucional.

La rejilla se adoptó antes de comparar modelos y conserva hitos de una, dos, cuatro, seis y ocho semanas. Las presentaciones duran entre 234 y 269 días; el corte 56 cae dentro del primer cuarto. La computabilidad y el calendario describen la pertinencia de la rejilla, pero no demuestran que sea óptima ni que se haya seleccionado sin conocimiento previo del desenlace. Los datos de calendario publicados permiten examinar la disponibilidad académica, presente ya al día 14.

7 Cascadas completas de elegibilidad

La Tabla 6 publica cada filtro y sus denominadores. Las exclusiones son secuenciales, no categorías superpuestas. Después del filtro de matrícula quedan 2 643 retiros preinicio; los 35 restantes de la fuente completa ya fueron excluidos por matrícula.

Tabla 6: Flujo secuencial en cada corte; las exclusiones corresponden a la etapa indicada.

Corte	Etapas	Inscripciones	Personas	Excluidas
7	Fuente	32 593	28 785	0
7	Matrícula conocida	32 548	28 755	45
7	Matriculada al corte	32 455	28 691	93
7	Sin retiro hasta corte	29 076	26 030	3 379
7	Final posterior al corte	29 076	26 030	0
14	Fuente	32 593	28 785	0
14	Matrícula conocida	32 548	28 755	45
14	Matriculada al corte	32 490	28 715	58
14	Sin retiro hasta corte	28 054	25 220	4 436
14	Final posterior al corte	28 054	25 220	0
28	Fuente	32 593	28 785	0
28	Matrícula conocida	32 548	28 755	45
28	Matriculada al corte	32 532	28 748	16

Corte	Etapas	Inscripciones	Personas	Excluidas
28	Sin retiro hasta corte	27 515	24 826	5 017
28	Final posterior al corte	27 515	24 826	0
42	Fuente	32 593	28 785	0
42	Matrícula conocida	32 548	28 755	45
42	Matriculada al corte	32 536	28 750	12
42	Sin retiro hasta corte	27 005	24 491	5 531
42	Final posterior al corte	27 005	24 491	0
56	Fuente	32 593	28 785	0
56	Matrícula conocida	32 548	28 755	45
56	Matriculada al corte	32 539	28 753	9
56	Sin retiro hasta corte	26 506	24 105	6 033
56	Final posterior al corte	26 506	24 105	0

8 Disponibilidad y calendario

El primer vencimiento continuo varía entre los días 12 y 61 según la presentación. En el corte 7 hay entregas anticipadas aunque no haya vencimientos. La falta de oportunidad no equivale a incumplimiento.

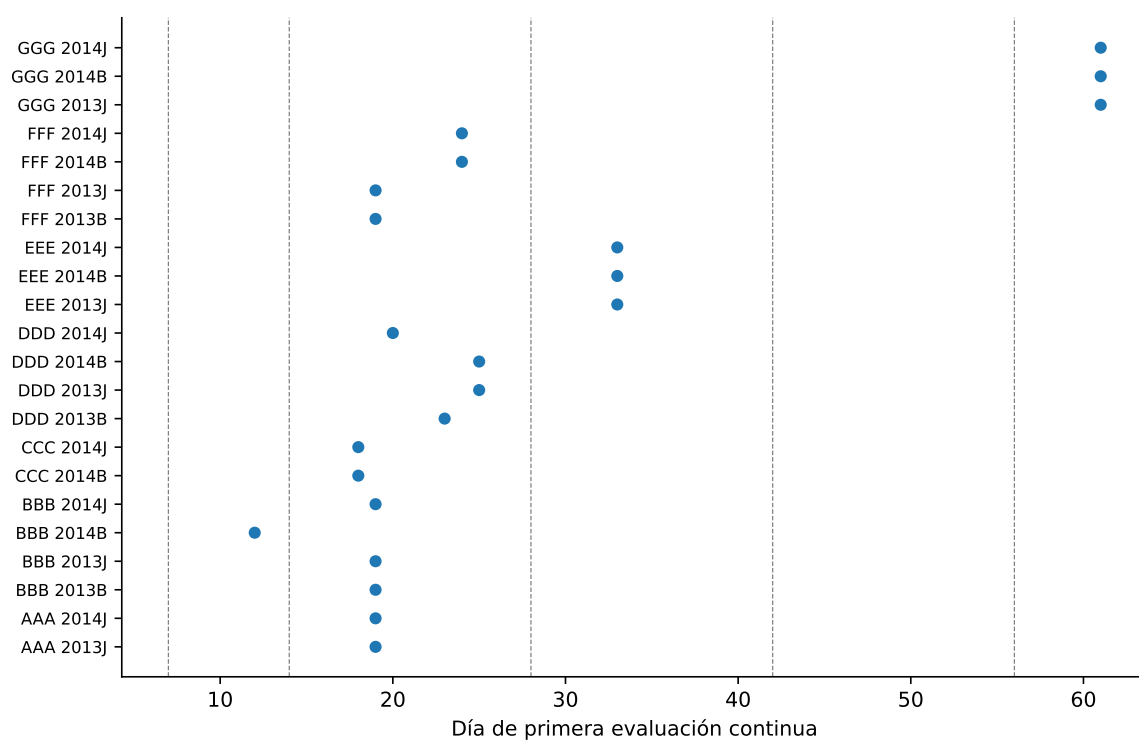


Figura 2: Primer vencimiento no Exam por módulo y presentación.

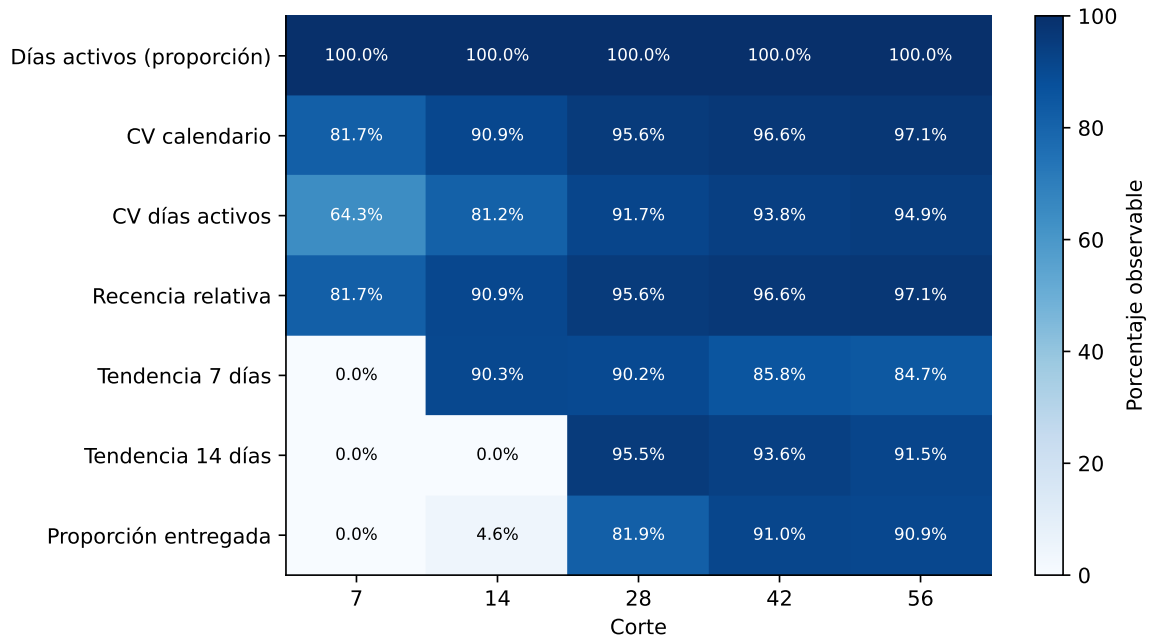


Figura 3: Observabilidad de cada indicador; porcentaje de inscripciones elegibles en cada corte.

9 Diccionario reconciliado de indicadores

Se documentan 26 candidatos, incluidos ambos CV; no se han seleccionado variables mediante desempeño predictivo. El conteo de filas aparece únicamente como auditoría. Los identificadores, el contexto y los desenlaces permanecen separados.

Tabla 7: Diccionario de candidatos y conteo de filas de auditoría; nombres idénticos al código.

Variable	Definición	Dominio y ausencia
total_clics	Suma de clics en 0..t	entero ≥ 0
días_activos	Días con clics en 0..t	0..t+1
proporcion_días_activos	días_activos/(t+1); calendario completo, no exposición individual	[0,1]
n_registros_vle	Filas de la fuente en 0..t; no son sesiones	entero ≥ 0
promedio_clics_por_día_activo	total_clics/días_activos	NaN sin actividad
coef_variacion_clics	SD muestral de t+1 totales diarios / media; incluye ceros	NaN sin actividad
cv_intensidad_activa	SD muestral / media de clics solo en días activos; intensidad condicional	NaN si días activos < 2
días_desde_ultima_interaccion	t - último día activo dentro de 0..t	NaN sin actividad
recencia_relativa	Recencia/(t+1)	NaN sin actividad
semanas_completas_activas	Bloques completos de 7 días desde 0 con actividad; omite bloque final parcial	0..floor((t+1)/7)
proporcion_semanas_completas_activas	Semanas completas activas / floor((t+1)/7)	[0,1]
clics_pre_inicio	Clics con fecha < 0	entero ≥ 0
sin_actividad_acumulada	1 si total_clics=0	0/1

Variable	Definición	Dominio y ausencia
sin_actividad_ultimos_7d	1 si no hay clics en t-6..t	NaN con menos de 7 días observados
sin_actividad_ultimos_14d	1 si no hay clics en t-13..t	NaN con menos de 14 días observados
sin_actividad_ultimos_28d	1 si no hay clics en t-27..t	NaN con menos de 28 días observados
clics_ultimos_7d	Clics en t-6..t	NaN si observación < 7 días
clics_7d_previos	Clics en t-13..t-7	NaN si observación < 14 días
log_ratio_7d	$\ln((\text{clics últimos 7d}+1)/(\text{clics 7d previos}+1))$	NaN con historia <14 días o cero en ambos bloques
log_ratio_14d	Razón logarítmica suavizada entre últimos dos bloques de 14 días	NaN con historia <28 días o cero en ambos bloques
n_evaluaciones_entregadas	Evaluaciones no Exam ni banked entregadas en 0..t	entero ≥ 0
n_entregas_pre_inicio	Entregas no Exam ni banked anteriores a 0	entero ≥ 0
n_evaluaciones_programadas	Evaluaciones no Exam con fecha de calendario en 0..t	entero ≥ 0
n_programadas_entregadas_al_corte	Evaluaciones programadas en 0..t entregadas hasta t, sin banked	0..n programadas
proporcion_programadas_entregadas	Entregadas programadas / programadas; no mide puntualidad	NaN si no hay programadas
sin_evaluacion_programada	1 si no existen evaluaciones programadas en 0..t	0/1
sin_entregas_acumuladas	1 si no hay entregas no Exam ni banked en 0..t; no implica incumplimiento	0/1

Referencias

- [1] Jakub Kuzilek, Martin Hlosta, and Zdenek Zdrahal. Open university learning analytics dataset. *Scientific Data*, 4:170171, 2017. DOI: 10.1038/sdata.2017.171.
- [2] Scikit-learn. Common pitfalls and recommended practices. https://scikit-learn.org/stable/common_pitfalls.html. Consultado el 8 de septiembre de 2026.