

Análisis estadístico comparado de cinco ventanas temporales

Oriana Giraldo Arcia

Luis Javier Rubio Hernández

Proyecto Aplicado de Ciencia de Datos, PUJ Cali

Revisión técnica: 10 de septiembre de 2026

1 Propósito y alcance estadístico

El análisis examina la distribución y las asociaciones de los indicadores construidos en los cortes 7, 14, 28, 42 y 56. Corresponde a una exploración previa al modelado: se analizan todos los datos elegibles y no se atribuyen a estos resultados propiedades de validación predictiva. Cada corte mantiene su propia población en riesgo y su evento futuro hasta el final de la presentación.

Se describen cuantiles, dispersión, faltantes y valores extremos. Los faltantes estructurales se separan de valores cero: no existe recencia definida sin actividad ni proporción de cumplimiento observable sin evaluaciones programadas. Los diagnósticos de valores atípicos mediante rango intercuartílico y desviación absoluta mediana no eliminan registros; cuando la escala es cero, el diagnóstico respectivo se conserva como no definido. Los patrones observados no demuestran mecanismos MAR o MNAR.

2 Asociaciones e incertidumbre dentro de cada corte

La comparación numérica usa el efecto biserial por rangos, calculado a partir del estadístico de Mann-Whitney con tratamiento de empates [4]:

$$r_{rb} = \frac{2U_1}{n_1n_0} - 1.$$

El grupo 1 corresponde al retiro futuro. Un efecto negativo indica valores generalmente menores en ese grupo y un efecto positivo indica valores mayores. Para cada indicador se utilizan los casos observables de ambos grupos; por ello, algunos denominadores cambian incluso dentro de un mismo corte. Las estimaciones no son efectos causales ni medidas del rendimiento de un clasificador.

Los intervalos puntuales del 95 por ciento se obtienen mediante 5000 remuestreos de personas con reposición, conservando conjuntamente sus inscripciones dentro del corte; se utiliza la semilla 20260908. Esta construcción reconoce la agrupación por estudiante [1]. Las presentaciones observadas permanecen fijas y no se incorpora incertidumbre por muestreo de cursos. Los intervalos son exploratorios, no simultáneos: no se presentan pruebas de significancia múltiples ni se usa su solapamiento como contraste entre ventanas.

Tabla 1: Efecto biserial por rangos en cada corte; no aplica indica ausencia de observaciones suficientes.

Indicador	7	14	28	42	56
Clics acumulados	-0,179	-0,147	-0,107	-0,111	-0,114
Proporción de días activos	-0,163	-0,132	-0,120	-0,121	-0,129
Recencia relativa	0,078	0,075	0,104	0,150	0,162
CV de calendario	0,109	0,109	0,126	0,129	0,140
CV entre días activos	-0,009	-0,004	0,038	0,037	0,045
Tendencia de 7 días	No aplica	-0,012	-0,064	-0,082	0,013
Tendencia de 14 días	No aplica	No aplica	0,046	-0,133	-0,093
Entregas acumuladas	-0,017	-0,064	-0,062	-0,065	-0,130
Proporción programada entregada	No aplica	-0,118	-0,135	-0,140	-0,200

Los clics acumulados y la proporción de días activos presentan asociaciones negativas con el retiro futuro en todos los cortes. El CV de calendario y la recencia relativa presentan asociaciones positivas; el CV entre días activos se evalúa separadamente. La dependencia entre variabilidad y frecuencia impide presentar estas asociaciones como evidencia independiente. Sin embargo, las magnitudes cambian al variar simultáneamente la historia observada, la población y el horizonte; no permiten afirmar que un corte sea superior a otro para predecir.




Figura 1: Efectos por corte e intervalos puntuales mediante remuestreo de personas. Las líneas conectan estimaciones y no representan un contraste longitudinal.

La tendencia de siete días en el corte 56 presenta un efecto de 0,013, con intervalo de -0,009 a 0,036. Este resultado no respalda una dirección clara de asociación para ese indicador en ese corte; tampoco demuestra ausencia de utilidad predictiva conjunta. La tendencia de catorce días conserva un significado distinto porque resume dos bloques de mayor duración.

3 Disponibilidad, distribución y heterogeneidad

La comparación de proporciones y recencias relativas reduce la dependencia aritmética de la duración observada, pero no iguala las oportunidades educativas. Las distribuciones empíricas se presentan por corte y las tablas completas conservan los tamaños observados y ausentes. La proporción entregada se analiza solo donde hay evaluaciones programadas; en el día 7 no existe este denominador y no se estima un efecto.




Figura 2: Distribuciones acumuladas de actividad relativa y recencia relativa; esta última excluye inscripciones sin actividad observable.

La V de Cramér se calcula como $V = \sqrt{\chi^2 / [N \min(f - 1, g - 1)]}$, donde N es el total de la tabla de contingencia y f, g sus dimensiones. Se utiliza como medida descriptiva de asociación, sin atribuir a su valor significancia estadística ni crecimiento necesario por desbalance de categorías.

Tabla 2: V de Cramér descriptiva; sin interpretación causal ni pruebas por filas independientes.

Categoría	7	14	28	42	56
Edad	0,026	0,016	0,012	0,011	0,011
Módulo	0,173	0,170	0,159	0,144	0,137
Presentación	0,082	0,059	0,043	0,040	0,033
Discapacidad	0,061	0,065	0,065	0,065	0,064
Género	0,035	0,029	0,029	0,025	0,024
Educación previa	0,071	0,057	0,051	0,045	0,038
Privación (IMD)	0,073	0,055	0,049	0,052	0,051
Región	0,043	0,026	0,026	0,027	0,029

La asociación con el módulo evidencia heterogeneidad contextual que debe considerarse al diseñar la validación. La V de Cramér no indica una dirección del efecto ni ajusta por otros atributos. Las tasas por nivel y los conteos se exportan por separado; no se interpreta una diferencia descriptiva como efecto atribuible a una característica personal.

4 Redundancia y estructura multivariada

Se calculan correlaciones de Spearman y cantidades de pares observados para cada corte. El diagnóstico VIF usa un conjunto reducido de cuatro indicadores con intercepto; sus valores describen dependencia lineal en ese conjunto y no ordenan automáticamente las variables por utilidad. La relación entre volumen de clics, días activos y filas VLE exige evitar interpretaciones de contribuciones completamente independientes.

El análisis de componentes principales utiliza cinco indicadores conductuales: logaritmo de uno más el volumen, proporción de días activos, logaritmo de uno más el promedio por día activo, recencia relativa y coeficiente de variación. Se restringe a casos con actividad y datos completos; cada corte se estandariza y ajusta separadamente [3]. Por ello, sus componentes no constituyen un sistema de ejes común para seguir trayectorias individuales entre ventanas.

Tabla 3: Resumen descriptivo del PCA ajustado separadamente por corte.

Corte	Casos observados	Varianza de dos componentes (%)
7	23 760	88,10
14	25 503	87,20
28	26 312	87,24
42	26 087	87,57
56	25 741	87,10

La covarianza robusta mediante MCD se ajusta sobre una muestra reproducible de 5 000 casos por corte y evalúa distancias en los casos completos [2]. La bandera usa el percentil empírico 97,5 de las distancias de todos los casos evaluados en ese corte. Este umbral es descriptivo, no una probabilidad calibrada de anomalía; no se utiliza una prueba de Hotelling ni se eliminan las observaciones marcadas. Las cargas de PCA, VIF y resúmenes MCD permanecen disponibles en CSV.

5 Sensibilidad con población y evento comunes

La intersección de las poblaciones elegibles contiene 26 429 inscripciones. Se fija para ellas el evento de retiro posterior al día 56 y hasta el final, con 3 985 eventos, y se describen nuevamente cinco indicadores en cada corte. Esta comparación mantiene población y etiqueta; los denominadores observables todavía cambian cuando un indicador requiere actividad o evaluaciones programadas.

Tabla 4: Efectos descriptivos en la cohorte común, sin intervalos ni contraste entre cortes.

Indicador	7	14	28	42	56
CV de calendario	0,067	0,082	0,103	0,114	0,140
CV entre días activos	-0,011	0,000	0,040	0,044	0,046
Tendencia de 7 días	No aplica	-0,010	-0,042	-0,074	0,013
Proporción de días activos	-0,074	-0,087	-0,089	-0,102	-0,128
Proporción programada entregada	No aplica	-0,097	-0,101	-0,118	-0,199

La selección exige conocer que una inscripción permanece elegible hasta el día 56. En consecuencia, es retrospectiva y condicionada a supervivencia administrativa; no puede utilizarse como población operativa de una alerta del día 7. La diferencia respecto de las asociaciones principales ayuda a reconocer el papel de la composición, pero no identifica causalmente su contribución ni permite atribuir a la duración de la ventana todo el cambio observado.

6 Resultados ampliados de las variables de contexto

Las categorías se analizan en las mismas poblaciones de cada corte. La Tabla 6 publica conteos y tasas por nivel; la categoría No disponible preserva los faltantes de IMD. Los resultados no se interpretan como efectos causales ni como una evaluación exhaustiva de equidad.

Tabla 5: Distribución y asociación de créditos e intentos previos; efecto biserial por rangos.

Corte	Variable	Observados	Ausentes	Mediana	Q25–Q75	Efecto
7	Créditos	29 076	0	60,000	60–90	0,165
7	Intentos previos	29 076	0	0,000	0–0	0,028
14	Créditos	28 054	0	60,000	60–90	0,138
14	Intentos previos	28 054	0	0,000	0–0	0,030
28	Créditos	27 515	0	60,000	60–90	0,131
28	Intentos previos	27 515	0	0,000	0–0	0,033
42	Créditos	27 005	0	60,000	60–90	0,125
42	Intentos previos	27 005	0	0,000	0–0	0,036
56	Créditos	26 506	0	60,000	60–90	0,119
56	Intentos previos	26 506	0	0,000	0–0	0,038

Los créditos representan la carga registrada y los intentos previos describen antecedentes de inscripción. Sus asociaciones no permiten distinguir mecanismos educativos ni efectos de modificar la carga. Se mantienen como contexto condicionado, sin incorporarlos automáticamente al conjunto de predictores conductuales.

Tabla 6: Retiros futuros / inscripciones elegibles (porcentaje) por nivel y corte.

Nivel	7	14	28	42	56
Edad / 0-35	4 796/20 383 (23,5%)	3 973/19 575 (20,3%)	3 550/19 166 (18,5%)	3 184/18 800 (16,9%)	2 825/18 443 (15,3%)
Edad / 35-55	1 796/8 491 (21,2%)	1 571/8 281 (19,0%)	1 431/8 156 (17,5%)	1 288/8 015 (16,1%)	1 150/7 878 (14,6%)
Edad / 55<=	40/202 (19,8%)	36/198 (18,2%)	31/193 (16,1%)	28/190 (14,7%)	23/185 (12,4%)
Discapacidad / N	5 780/26 298 (22,0%)	4 833/25 379 (19,0%)	4 335/24 908 (17,4%)	3 886/24 461 (15,9%)	3 447/24 025 (14,3%)
Discapacidad / Y	852/2 778 (30,7%)	747/2 675 (27,9%)	677/2 607 (26,0%)	614/2 544 (24,1%)	551/2 481 (22,2%)
IMD / 0-10%	773/2 855 (27,1%)	622/2 706 (23,0%)	560/2 646 (21,2%)	514/2 601 (19,8%)	458/2 545 (18,0%)
IMD / 10-20	765/3 042 (25,1%)	610/2 890 (21,1%)	541/2 823 (19,2%)	495/2 777 (17,8%)	443/2 725 (16,3%)
IMD / 20-30%	881/3 217 (27,4%)	723/3 060 (23,6%)	640/2 979 (21,5%)	581/2 920 (19,9%)	522/2 861 (18,2%)
IMD / 30-40%	733/3 177 (23,1%)	604/3 055 (19,8%)	541/2 997 (18,1%)	483/2 939 (16,4%)	425/2 882 (14,7%)
IMD / 40-50%	671/2 886 (23,3%)	554/2 773 (20,0%)	493/2 714 (18,2%)	432/2 653 (16,3%)	389/2 611 (14,9%)
IMD / 50-60%	590/2 810 (21,0%)	515/2 739 (18,8%)	462/2 688 (17,2%)	409/2 635 (15,5%)	362/2 588 (14,0%)
IMD / 60-70%	598/2 640 (22,7%)	513/2 559 (20,0%)	458/2 509 (18,3%)	416/2 467 (16,9%)	366/2 417 (15,1%)
IMD / 70-80%	526/2 608 (20,2%)	464/2 549 (18,2%)	426/2 515 (16,9%)	378/2 468 (15,3%)	328/2 418 (13,6%)
IMD / 80-90%	495/2 485 (19,9%)	428/2 418 (17,7%)	385/2 377 (16,2%)	340/2 332 (14,6%)	304/2 297 (13,2%)
IMD / 90-100%	428/2 312 (18,5%)	383/2 268 (16,9%)	354/2 240 (15,8%)	314/2 200 (14,3%)	279/2 165 (12,9%)
IMD / No disponible	172/1 044 (16,5%)	164/1 037 (15,8%)	152/1 027 (14,8%)	138/1 013 (13,6%)	122/997 (12,2%)
Región / East Anglian Region	633/2 962 (21,4%)	521/2 851 (18,3%)	469/2 803 (16,7%)	418/2 752 (15,2%)	370/2 707 (13,7%)
Región / East Midlands Region	510/2 059 (24,8%)	416/1 966 (21,2%)	372/1 922 (19,4%)	339/1 889 (17,9%)	299/1 849 (16,2%)
Región / Ireland	221/1 111 (19,9%)	214/1 114 (19,2%)	192/1 105 (17,4%)	172/1 085 (15,9%)	156/1 069 (14,6%)
Región / London Region	705/2 815 (25,0%)	523/2 635 (19,8%)	460/2 572 (17,9%)	420/2 532 (16,6%)	381/2 493 (15,3%)
Región / North Region	386/1 629 (23,7%)	322/1 567 (20,5%)	283/1 530 (18,5%)	262/1 509 (17,4%)	231/1 478 (15,6%)
Región / North Western Region	606/2 479 (24,4%)	513/2 390 (21,5%)	452/2 331 (19,4%)	398/2 277 (17,5%)	340/2 219 (15,3%)
Región / Scotland	655/3 202 (20,5%)	644/3 192 (20,2%)	610/3 160 (19,3%)	558/3 108 (18,0%)	509/3 059 (16,6%)
Región / South East Region	410/1 872 (21,9%)	337/1 799 (18,7%)	303/1 767 (17,1%)	264/1 729 (15,3%)	234/1 699 (13,8%)
Región / South Region	586/2 758 (21,2%)	501/2 674 (18,7%)	447/2 622 (17,0%)	401/2 576 (15,6%)	350/2 525 (13,9%)

Nivel	7	14	28	42	56
Región / South West Region	512/2 193 (23,3%)	411/2 093 (19,6%)	369/2 051 (18,0%)	335/2 017 (16,6%)	310/1 992 (15,6%)
Región / Wales	418/1 983 (21,1%)	378/1 944 (19,4%)	343/1 910 (18,0%)	310/1 877 (16,5%)	275/1 842 (14,9%)
Región / West Midlands Region	568/2 238 (25,4%)	459/2 133 (21,5%)	413/2 088 (19,8%)	362/2 037 (17,8%)	325/2 000 (16,2%)
Región / Yorkshire Region	422/1 775 (23,8%)	341/1 696 (20,1%)	299/1 654 (18,1%)	261/1 617 (16,1%)	218/1 574 (13,9%)

7 VIF publicado y decisión sobre el conteo de filas

Tabla 7: VIF con intercepto en la especificación de auditoría de cuatro indicadores.

Corte	n	Clics	Proporción activa	Filas VLE	Entregas
7	29 076	3,707	3,388	6,656	1,052
14	28 054	4,452	4,045	8,495	1,049
28	27 515	5,235	4,696	10,929	1,319
42	27 005	5,839	5,372	12,334	1,323
56	26 506	6,157	5,673	13,694	1,394

El mayor VIF corresponde al conteo de filas en cada corte y llega a 10,929 al día 28. Se conserva esta especificación como diagnóstico de la decisión de exclusión; no es el conjunto predictivo final. La redundancia y la procedencia no resuelta del conteo se consideran conjuntamente, sin imponer un umbral universal para todos los modelos.

8 Sensibilidad de variabilidad y componentes principales

Tabla 8: Correlación con proporción activa en los mismos casos con al menos dos días activos.

Corte	CV calendario observable	CV activo observable	Rho calendario	Rho activo
7	23 760	18 704	-0,848	0,126
14	25 503	22 779	-0,892	0,153
28	26 312	25 227	-0,909	0,102
42	26 087	25 323	-0,918	0,102
56	25 741	25 147	-0,926	0,076

El CV activo separa mejor la dispersión de intensidad de la frecuencia en estos datos, a costa de una menor observabilidad. No se identifica independencia estadística ni ganancia predictiva. El CV de calendario combina ambos componentes y no se descarta retrospectivamente como cálculo erróneo. En los cortes 7 y 14, los intervalos puntuales del CV activo incluyen cero y no respaldan una dirección clara. Esta diferencia respecto del CV de calendario muestra que cambiar la definición modifica la interpretación del indicador; no prueba ausencia de utilidad conjunta en un clasificador.

Tabla 9: Varianza porcentual de dos componentes; comparación descriptiva sobre la misma población.

Corte	n común	Original (5)	Sin volumen (4)	CV activo (4)
7	18 704	84,27	80,53	68,57
14	22 779	84,73	81,25	69,00
28	25 227	85,95	82,91	70,48
42	25 323	86,61	83,72	70,76
56	25 147	86,34	83,41	69,77

La especificación original incluye logaritmos de volumen e intensidad, proporción activa, recencia relativa y CV de calendario. La segunda retira volumen; la tercera sustituye además el CV por su versión activa. Todas se ajustan separadamente por corte y se estandarizan. Cambiar el número y significado de las variables cambia el total de varianza: un porcentaje mayor no acredita una representación superior ni explica mayor proporción del abandono.

9 Sensibilidad de asociaciones a los duplicados exactos

Tabla 10: Cambio del efecto biserial al retirar exactos: alternativa menos fuente original.

Indicador	7	14	28	42	56
CV calendario	-0,0007	-0,0001	0,0005	0,0003	0,0009
CV activo	-0,0024	-0,0013	-0,0004	-0,0003	0,0007
Tendencia 14	No aplica	No aplica	-0,0002	0,0013	0,0004
Tendencia 7	No aplica	0,0011	0,0005	0,0000	0,0008
Proporción activa	0,0000	0,0000	0,0000	0,0000	0,0000
Recencia	0,0000	0,0000	0,0000	0,0000	0,0000
Clics	0,0001	0,0007	0,0007	0,0011	0,0014

La alternativa elimina repeticiones en todas las columnas de la fuente antes de agregar; conserva población y evento. La actividad original sigue siendo el análisis principal. Estas diferencias cuantifican sensibilidad descriptiva, no identifican cuál registro es verdadero ni prueban robustez de un modelo aún no entrenado.

10 Estabilidad de los intervalos por remuestreo

Tabla 11: Cambio máximo de extremos entre 2.000 y 5.000 remuestreos; comparación numérica, no contraste de hipótesis.

Corte	Indicadores	Cambio máximo	Dentro de 0,005
7	11	0,0006	11
14	13	0,0030	13
28	14	0,0009	14
42	14	0,0008	14
56	14	0,0013	14

Se compararon los primeros 500 y 2 000 remuestreos con los 5 000 de la misma secuencia reproducible. Se fijó una tolerancia descriptiva de 0,005 unidades del efecto para comparar extremos. Las secuencias son anidadas: este diagnóstico no demuestra convergencia con semillas independientes ni elimina error Monte Carlo. Los intervalos publicados utilizan 5 000 remuestreos y permanecen puntuales y exploratorios.

11 Conclusiones y continuidad

La comparación documenta que la disponibilidad académica y el significado de los indicadores cambian con el momento de observación. Las señales conductuales conservan asociaciones descriptivas con el retiro, mientras que algunas tendencias recientes presentan resultados menos definidos. La evidencia favorece mantener explícitos los denominadores, el calendario y la historia requerida, en lugar de completar automáticamente con ceros los indicadores no observables.

Los resultados preparan la comparación posterior de modelos, pero no establecen una ventana óptima. Esa decisión requerirá evaluar discriminación, calibración y utilidad de anticipación bajo particiones compatibles y un protocolo fijado antes de seleccionar modelos, umbrales o cortes. La exploración ya realizada sobre la fuente completa debe declararse al evaluar la independencia de una prueba final; no se presenta ningún subconjunto como intacto por el solo hecho de asignarle después ese nombre.

Referencias

- [1] C. A. Field and A. H. Welsh. Bootstrapping clustered data. *Journal of the Royal Statistical Society: Series B*, 69(3):369–390, 2007. DOI: 10.1111/j.1467-9868.2007.00593.x.
- [2] Scikit-learn. Documentation: Mincovdet. <https://scikit-learn.org/stable/modules/generated/sklearn.covariance.MinCovDet.html>. Consultado el 8 de septiembre de 2026.
- [3] Scikit-learn. Documentation: Pca. <https://scikit-learn.org/stable/modules/generated/sklearn.decomposition.PCA.html>. Consultado el 8 de septiembre de 2026.
- [4] SciPy. Documentation: mannwhitneyu. <https://docs.scipy.org/doc/scipy/reference/generated/scipy.stats.mannwhitneyu.html>. Consultado el 8 de septiembre de 2026.